

머신러닝과 비재무적 정보를 이용한 부실 확률 예측 모형 : 탄소배출정보, ESG 성과, 애널리스트 정보를 중심으로

2023. 1

이정환 · 조진형

머신러닝과 비재무적 정보를 이용한 부실 확률 예측 모형 : 탄소배출정보, ESG 성과, 애널리스트 정보를 중심으로

이정환* · 조진형**

* 한양대학교 경제금융대학 부교수, E-mail: jeonglee@hanyang.ac.kr

** 한양대학교 ESG정책분석센터 객원연구원(경제학 박사),
E-mail: enish27@hanyang.ac.kr

목차

I. 서론	1
II. 선행연구	7
1. 탄소배출량 정보와 기업 신용등급	7
2. ESG 성과와 기업 신용등급	8
3. 애널리스트 정보와 기업 신용평가	10
III. 표본과 연구 모형	13
1. 표본과 데이터 구축	13
2. 비자발적 상장폐지 기업 및 부도거리	16
3. 머신러닝 모형	18
4. 부도거리 분석 모형	22
IV. 연구결과	24
1. 머신러닝 성과	24
2. 비자발적 상장폐지 기업 분석	31
3. 대안신용 정보와 부도거리 분석	34
V. 결론	50
VI. 참고문헌	52
Abstract	57

한국금융연구원 홈페이지(www.kif.re.kr > 보고서 > 연구보고서)를 이용하시면,
본 발간물의 그림, 표를 컬러로 보다 상세하게 확인하실 수 있습니다.

요 약

본 연구는 대안 신용평가 모형 구축을 위한 기초 분석으로서 기존 신용평가사 모형을 머신러닝 방법을 통해 학습하여 비자발적 상장 폐지 기업에 대해 확장 분석하고, 탄소배출량, ESG 성과, 애널리스트 커버리지 등 대안 정보의 활용 가능성에 대해서 분석하였다.

본 연구에서는 머신러닝 모형 적용을 통해 신용등급 예측이 매우 우수하게 학습될 수 있다는 사실을 밝혔다. 또한 이와 같은 학습된 로직을 기존 연구에서는 신용 등급이 없어 분석이 불가능한 비자발적 상장 폐지 기업에 적용해본 결과 재무제표에 기반한 전통적인 신용평가 모형이 이들 기업의 패턴을 적절히 설명하고 있음을 확인하였다.

한편 본 연구는 향후 대안 신용 평가 모형에 있어 ESG 정보 중 지배구조 성과가 기업의 부도 확률을 줄여주는 효과가 있는 것을 강건하게 확인하였다. 그러나 ESG 중 사회 및 환경영역 정보나, 애널리스트 커버리지, 탄소 관련 정보는 부도거리와 관계가 유의하지 않은 것을 확인하였다.

본 연구의 주요 공헌점은 다음과 같다. 첫째, 본 연구는 머신러닝 모형을 바탕으로 채권 발행기업 위주로 한정적으로 제공되던 신용평가 관련 분석을 다양한 표본 기업에 대해 확장할 수 있는 프레임워크를 제시하였다. 이러한 프레임워크를 통해 비자발적 상장 폐지를 신용 등급 관련 연구와 연결시키고, 기업의 최종적인 부실은 비재무적 요소가 아닌 재무적 요소로 결정됨을 확인하였다. 한편 본 연구는 ESG 정보 중 지배구조 정보가 추후 신용 등급 평가에 반영할 수 있는 주요한 정보가 될 수 있음을 확인하였으며, 탄소배출이나 환경과 같은 정보들을 향후 대안 신용 평가 모형 활용 시 환경 위험 인식 변화에 따른 추가 분석을 수행해야 됨을 밝히고 있다.

I. 서론

신용평가는 기업의 채무상환능력을 평가하여 이를 등급화하는 과정이다. 신용 등급 평가는 크게 기업의 재무 정보에 기초한 재무평가와, 수치적인 계량화가 어려운 비(非)재무적 요소에 대한 평가로 구성된다. 이와 같은 평가를 기반으로 신용평가사는 채권 발행기업의 사업위험, 재무위험, 발행조건을 다각적으로 검토하여 해당 기업의 신용등급을 결정하게 된다. 신용평가는 투자자와 발행기업, 궁극적으로 금융시장 전반에 대하여 기능을 수행하는 자본시장의 핵심 요소라고 할 수 있다. 투자사는 투자에 따른 리스크를 줄이기 위한 자료를 제공함으로써 미래 불확실성을 줄이고, 투자 의사결정에 따른 비용을 줄일 수 있다. 반면 발행 회사 입장에서는 자사의 신용도를 고려한 자금조달 계획을 수립함으로써 대외 신뢰도를 끌어올릴 수 있다. 끝으로 객관적인 신용평가는 금융시장 전반으로 중개 비용을 줄여나감에 따라 국가 경제의 효율성을 개선시키는 기능을 한다고 볼 수 있다.

근래 들어 국내 학계에서 금융·자본 데이터 분석과 이에 기초한 비즈니스 결정 과정이 중요하게 여겨지고 있다(송성환 외, 2017; 서문석·김동호, 2019; 서민교, 2014; 윤보현 외, 2016; 이재웅 외, 2016). 그러나 상당수 선행연구는 은행 신용공여, 소상공인, 채무불이행 예측 등 특정 사례에 한정되어 있거나, 전통 회귀분석법에 의존하고 있는 등 대안 신용평가를 위한 머신러닝 모형의 예측 성능을 분석한 연구는 현저히 부족한 실정이다(권황현, 2020; 박주완 외, 2017; 송민찬·류두진, 2021). 그나마 개별 기업 차원에서는 카카오뱅크·JT저축은행 등이 고객을 대상으로 한 신용평가 모형을 만들고 있지만 이는 개인 신용을 대상으로 한 빅데이터 기반의 신용평가 분석이며 기업 신용등급 분석과는 차이가 있다고 할 수 있다.¹⁾ 근래 들어 일부 금융권을 중심으로 기업 부문 대안신용평가 모형을 마련하려는 움직임이 감지되고 있지만, 보다 다양한 기업을 대상으로 한 비재무정보 평가 모형 개발은 아직

1 <https://www.mk.co.kr/news/economy/view/2022/03/281480/>
<https://www.bloter.net/newsView/blt202106090002>

개발이 더디다고 할 수 있다.²⁾

기존 재무지표 기반의 신용평가 모형의 가장 큰 한계는 다양한 사유로 발생하는 기업 부실을 설명하기 어렵다는 것이다. 이를테면 최근 들어 ESG, 탄소배출 등 비재무 성과가 중요해지며 MSCI 등 해외 신용평가사들이 비재무적 정보를 신용 평가에 반영하려고 하고 있다. 그러나 아직 국내 신용평가 모형은 재무지표를 중심으로 한 신용평가 등급을 매기고 있으며, 회사채를 발행하는 기업을 위주로 평가하고 있다.

본 연구는 비재무적 정보의 신용평가 활용 가능성을 분석하기 위해 크게 두가지 방향으로 접근했다. 먼저 기존 신용평가 모형이 신용등급이 없는 기업에 대해서도 실제 부실을 잘 예측하고 있는지 분석하고 관련 시사점을 도출하였다. 두 번째로 상장기업의 ESG 성과, 탄소배출량, 애널리스트 커버리지 등 다양한 비재무 정보를 이용함으로써 이런 정보가 실제 기업의 부실 위험에 대하여 예측 능력을 갖추고 있는지 검증하였다.

기존 기업의 신용평가 모형이 실제 부실을 잘 예측하고 있는지 분석하기 위하여, 비자발적 상장 폐지 기업에 대해 머신러닝 기법을 활용하여 분석하였다. 실제 정확한 신용평가 방식은 신용평가사의 자산이기 때문에 외부에 알려질 수 없다. 이에 따라 다양한 재무성과 지표를 중심으로 한 머신러닝 모형을 통해 신용평가사의 로직을 재현해 보았으며, 머신러닝 기반 스코어링이 상장폐지 기업들의 상황들을 잘 예측할 수 있는지 검토하였다. 등급 예측 모형에서 활용도가 높은 랜덤포레스트와 그래디언트부스팅디시전트리(GBDT) 등 머신러닝 모형을 활용하여 기업의 투자등급(BBB)에 대한 확률예측값을 추정하였다. 전통적인 로지스틱 회귀 모형은 비교를 위해 추가적으로 분석하였다.

한편 국내 유가증권시장 상장사의 경우 실제 기업의 파산에 이르러 워크아웃에 가는 경우가 매우 드물다. 이에 따라 투자자 입장에서 부도에 준하는 이벤트라고 할 수 있는 비자발적 상장폐지 기업들을 일종의 부실 기업으로 분류하여 국내 신용 평가사 모형이 이러한 기업들의 부실을 잘 설명하고

2 <https://news.mt.co.kr/mtview.php?no=2022071110284518752>

있는지 확인하였다. 이와 같이 비자발적인 상장폐지에 이르는 기업들은 채권을 발행할 수 없을 정도로 부실한 기업들이라 머신러닝 기법을 통해 신용평가사의 로직을 적용할 수 있었다.

만약 이러한 전통적인 신용평가사의 로직이 이와 같은 비자발적인 상장폐지 기업에 대해 높은 설명력을 가지고 있다고 한다면, 직접적인 부실 기업에 대한 비재무적 정보 등 대안 정보의 신용 평가 과정에서의 활용 필요성은 그리 크지 않은 것을 시사한다. 다시 말해 기업의 최종적인 부실은 재무적인 성과에 기인한 것으로, 비재무적인 정보는 이러한 최종적인 부도로 이끄는 재무적인 위험을 조절하는(moderating) 요소로 보는 것이 타당하다는 것이다.

또한 신용평가사의 평가로직이 재무제표를 통한 머신러닝의 학습을 통해 원활히 이루어진다고 하면, 머신러닝에 의한 예측 변수를 조절 변수 삼아 다양한 대안 신용평가 모형을 분석하기 위한 프레임워크로 이용할 수 있다. 실제로 신용평가사의 신용 평가는 채권 발행을 하는 기업에 집중되어 있으며, 그 평가 역시 일부 회계연도에 대해서는 결측치가 있는 경우가 많다. 이에 따라 신용평가의 영향 분석에 있어서 분석 표본의 대표성에 제한이 있는 한계점이 있는 것이 사실이었으며, 다양한 신용 평가 연구에 있어서 제약으로 작용하였다. 실제 본 연구에서 사용한 2010년부터 2020년까지 ESG 점수가 있는 기업-회계연도 쌍 중에서 NICE 기준 신용 정보가 있는 기업은 표본의 24.5% 수준으로 이들 기업에 대해서만 신용등급을 고려한 후 분석하게 된다면 그 표본의 대표성에 상당한 문제가 있는 수준이다.

다음으로 비재무적 성과와 기업의 부실과의 관련성을 일반적으로 분석하기 위해 본 연구는 Merton(1974)이 도입한 부도거리(Distance to Default)를 사용하였다. 이 부도거리는 기업의 위험을 파악하기 위해 규제 당국이나 연구자들이 널리 사용하는 척도로써³⁾ 부도거리가 클수록 기업의 건전성이 높은 것으로 판단할 수 있다. 이 부도거리를 종속변수로 고려하고, 상장기업의

3 Merton의 모형에 따르면 부도거리 이외에 부도 확률 역시 계산될 수 있다. 그러나 부도 확률의 경우 많은 기업들이 0에 가깝게 집중되어 있으므로 일반적인 패널 회귀 분석에 사용하기는 어려운 것으로 알려져 있다.

ESG 성과, 탄소배출량, 애널리스트 커버리지를 독립 변수로 고려하고, 머신러닝으로 예측한 부도확률 및 다른 여러 가지 기업 변수들을 조절 변수로 하여 패널 회귀 분석을 실시하였다.

이러한 분석은 대안신용 평가 모형 수립을 위한 기초적인 작업이라고 할 수 있다. 실제 대안 신용 평가 모형을 수립하기 위해서는 기업 가치 변동성과 레버리지로 결정되는 부도 확률 이외에도 추가적인 재무 요인들이 있다. 그러나 시장요인을 통해 계산하는 부도확률과 부도거리는 기업의 부실 가능성을 나타내는 가장 유용한 측도 중 하나로 활용되고 있으며, 이러한 부도거리와 비재무적 정보와의 관계 분석을 통해 비재무적 정보의 대안 신용 평가 모형 활용 가능성을 추론할 수 있다.

본 연구의 주요 분석 결과는 다음과 같다. 우선 재무제표 및 거시 경제 변수 기반으로 신용 등급에 대한 머신러닝 분석을 수행해 본 결과, 전통적인 로지스틱 회귀 모형과 달리 랜덤포레스트와 그래디언트부스티드디시전트리(GBDT)는 기업 신용 상태가 건전한 기업뿐만 아니라 부실한 기업에 대한 예측을 매우 정확도 높게 수행하였다. BBB 이하 신용 등급 기업에 대한 설명력이 떨어지는 로지스틱 회귀 모형과 달리, 랜덤포레스트 및 그래디언트 부스티드디시전트리의 경우 BBB 이하 신용 등급 기업 및 BBB 초과 신용 등급 기업들에 대해 정확도가 각각 94%가 넘을 정도로 높은 성과를 보여주었다.

한편 이렇게 학습한 현재 국내 신용 평가사의 등급 산정 로직을 바탕으로 비자발적 상장폐지 기업을 분석해 본 결과 머신러닝 모형의 설명력이 높은 것으로 나타났다. 즉 이들 기업의 재무제표를 기반으로 상장 폐지 당시의 BBB 등급 이하의 확률을 구해본 결과 범죄 연루 등으로 재무 상태와 상관없이 상장폐지된 몇몇 기업이 존재함에도 불구하고 평균 88%, 중위값 95% 이상의 높은 예측력을 보였다. 이러한 상장폐지 기업에 대해 또한 상장폐지 이전의 부도 확률을 예측해본 결과, 평균 80% 이상의 값을 지니며 상장폐지 기준일까지 점차 증가하는 양상을 보여 경제적인 합리성도 높은 것으로 나타났다. 이는 기업의 최종적인 부실 판별은 전적으로 유동성이나 현금흐름과 같은 재무성과의 영역이라는 것을 시사한다. 이미 언급한 바와 같이 비재무적

정보는 이러한 직접적인 부실 위험보다는 등급 체계 내에서 추가적인 변동을 설명하는 요인으로 사용하는 것이 바람직한 것일 수 있음을 의미한다.

한편 이러한 부실 확률 예측치를 기존 신용평가에 대한 대응 변수로 고려하여 가용 표본을 증가시킨 후 부도거리와 비재무적 정보와의 관련성을 분석한 결과는 다음과 같다. 우선 ESG 지표는 향후 신용 평가 등급 체계 개선에 활용될 가능성이 있는 것으로 나타났다. 전통적인 지배구조 영역에서의 성과는 기업의 부도거리를 늘리는 쪽으로 작용하고, 이는 특히 비재벌 기업에서 명확하게 확인되었다. 한편 환경 성과와 부도거리는 음의 관계가 나타나는 등 환경 성과가 높은 기업에서 부실 확률이 높아지는 상황이 발생하였다. 아직까지 환경경영을 재무성과에 부정적인 요인으로 고려하거나, 혹은 표본 기간 내에서 재무 성과에 집중하여 환경경영을 하지 않았던 기업이 많았을 가능성을 시사한다. 그러나 환경성과가 0이 아닌 기업들에 대해서는 통계적 유의성이 사라져 부도거리와 매우 강건한 관계를 가지지는 않는 것으로 확인되었다.

반면 애널리스트 커버리지 정보, 그리고 탄소배출량과 같은 대안 정보는 기업의 부도거리에 대한 설명력이 낮은 것으로 나타났다. 탄소배출량의 경우 현재 가격이 매우 낮게 측정된 탄소배출권의 가격이 기업의 재무지표에 추가적인 영향을 주지 않아 설명력이 낮을 가능성이 존재한다. 애널리스트 커버리지의 경우 애널리스트들의 주요 분석 대상이 부실 가능성이 낮고 우량한 기업일 가능성이 높고, 이에 따라 부도거리에 추가적인 설명력이 낮을 수 있는 것으로 판단된다.

본 연구의 공헌점은 다음과 같다. 첫째, 본 연구는 머신러닝 모형을 도입하여 기존의 재무기반 신용 평가 모형을 보다 광범위하게 적용할 수 있는 방법론을 제시하였다. 특히 전통적인 로짓 모형에 비하여 머신러닝 기반의 모형은 신용평가사의 의사결정에 대하여 우수한 예측 성과를 보이는 것으로 나타났다. 이를 통해 등급 평가 대상의 수가 한정된 신용 평가사의 결정을 시뮬레이션하여 일반적인 기업 표본에 대해 확장할 수 있는 방법론을 제시하였다. 특히 기존 신용등급을 넘어서 다양한 표본에 대해 대안적인 분석을 해야 하는 향후 대안 신용 평가 모형에 있어서 활용도가 높을 것으로 사료된다.

둘째, 기존에 논의가 부족하였던 비자발적 상장폐지 기업을 분석 대상으로 하여 기업 부실과의 관계를 명확하게 밝혔다는 측면이 있다. 비자발적 상장 폐지는 투자자 입장에서는 기업의 부도와 거의 준하는 이벤트로 사료될 수 있으나, 아직까지 연구가 활발하게 진행되지는 않았다. 따라서 채권 발행이 이미 어려워짐에 따라 이와 같이 신용 등급이 없는 비자발적 상장 폐지 기업에 대해서 신용 등급 관련 연구 분야를 확장했다는 점에서 본 연구는 또 다른 공헌점이 있다고 할 수 있다. 더욱이 본 연구의 결과는 이러한 비자발적 상장폐지기업들이 최종적으로는 재무적 지표에 기반한 기존 모형으로 잘 설명되고 있음을 밝혀, 비재무적인 정보는 이러한 최종적인 부실로 이끄는 재무적인 위험을 억제하는 조절요소(moderating factor)로 보는 것이 타당함을 시사한다.

셋째, ESG 정보가 추후 신용 등급 평가에 반영할 수 있는 주요한 정보가 될 수 있음을 확인하였다. 특히 지배구조 관련 정보는 기업의 가치나 가치 변동성과 밀접하게 연관될 수 있고, 이에 따라 향후 기업의 부실위험을 예측하는 데 설명력을 높일 수 있는 것으로 나타나고 있다. 이에 따라 지배구조 개선이 기업의 신용평가 향상에 미칠 수 있는 가능성을 확인했다.

마지막으로 본 연구는 탄소 등 증권사 커버리지 등의 정보와 같은 비재무적 정보에 대해서는 향후 추가적인 분석이 필요할 수 있음을 시사한다. 특히 탄소배출권 가격 변화와 같은 외부 환경 변화, 증권사 보고서의 자연어 처리 분석 등을 통한 추가적인 분석이 필요함을 시사한다.

본 연구보고서의 구성은 다음과 같다. II장에서는 선행연구 및 문헌을 고찰한다. III장에서는 연구 모형과 표본에 대해서 분석한다. IV장에서는 머신러닝 분석 성과와 비자발적 상장 폐지 기업에 대한 분석을 수행하고 부도거리와 ESG, 탄소배출 성과, 애널리스트 커버리지와 관련성을 분석한다. V장에서는 결론을 도출하여 대안 신용 평가 모형에 대한 시사점을 논의한다.

Ⅱ. 선행연구

1. 탄소배출량 정보와 기업 신용등급

근래 들어 기업의 탄소배출량과 기업가치에 대하여 활발한 연구가 진행되었다(Matsumura et al., 2014; 박정환 외, 2017; 최종서와 노정희, 2016). 국내외 연구는 탄소배출량과 기업가치의 음(-)의 관계를 주목하였다. Matsumura et al.(2014)은 미국의 S&P500 기업을 대상으로 탄소배출량과 기업가치의 관계를 분석한 결과 두 변수 사이 유의한 음(-)의 관계를 발견하였다. Chapple et al.(2013) 역시 탄소배출권을 공개 거래하는 호주 기업을 대상으로 가치평가모형을 통하여 분석한 결과, 탄소배출량과 기업 주가 사이에 유의한 음(-)의 관계를 확인하였다. 또한 Vance(1975)는 기업의 환경성과와 기업 가치의 관계를 분석한 결과, 우수한 환경성과 달성에 있어 기업 내부의 자원이 소요되며 그 결과 두 변수 사이에 음(-)의 관계가 발견된다고 주장하였다.

국내 연구에서도 탄소배출량과 기업 가치 사이에 나타나는 부정적인 관계를 주목하고 있다. 박정환 외(2017)는 탄소배출량이 기후변화 위험을 반영하는 것으로 작용하여 기업가치 하락에 영향을 끼치는 것으로 분석하였다. 이들은 2011~2014년의 국내 기업이 탄소배출공개프로젝트(CDP) 보고서에 공시한 탄소배출량 정보와 토빈의 큐(Tobin-Q)로 측정한 기업가치를 실증 분석한 결과 두 변수 사이에 유의한 음(-)의 관련성이 있음을 증명하였다. 최종서와 노정희(2016)는 탄소배출량 정보의 가치 분석에 있어 자기선택 편의를 교정하여 검증한 결과 탄소배출량과 주가 사이의 관련성에 있어 변동 분석 측면에서 강력한 음(-)의 상관관계를 검증하였다. 이처럼 전반적으로 국내외 선행연구는 탄소배출 정보와 기업 가치의 음의 관계를 보고하고 있다는 사실을 알 수 있다.

그러나 일부 국내 연구는 국내 기업의 특성을 고려하여, 탄소배출량과

기업가치 간의 양(+)의 관계가 존재할 수 있다는 점을 언급하고 있다. Lee and Cho(2021)는 841개의 국내 기업을 514개의 재벌기업집단과 335개의 비재벌기업집단으로 구분하여, 국내 CDP 보고서에서 수집한 탄소 배출량과 기업별 재무 데이터를 분석하였다. 그 결과 재벌기업집단의 탄소 배출량과 기업 가치 사이에 양(+)의 관계가 있다는 사실을 밝혀냈다. 이는 투자자들이 탄소배출량이 기업가치에 부정적 영향을 끼친다는 선진국 위주의 선행 연구와 대조되는 결과이다. 또한 이들의 연구는 자발적인 탄소배출 공시 여부와 관련하여, 환경 성과가 높은 국내 기업은 자사의 탄소 배출 정보를 자발적으로 공개하는 경향이 있다는 사실을 증명하였다. 또한 안미강과 고대영(2017)은 2010년부터 2014년까지 CDP 보고서에서 탄소배출 정보가 공개된 기업을 대상으로 분석한 결과 탄소배출 공시 변수가 공적부채 변수와 금융부채 변수에 유의한 양(+)의 영향을 끼친다는 점을 보고하였다. 다시 말해, 부정적인 정보로 간주될 수 있는 탄소배출 정보를 자발적으로 공개하는 것은 기업이 사회적 책임을 수행한다는 신호효과를 얻으며, 기업의 정보비대칭 면에서 보다 우위를 가짐으로써 더 용이한 타인자본 조달을 가능케 한다는 것이다.

위와 같은 논의를 종합하면, 탄소배출량 정보가 각종 부채와 양(+)의 관계를 갖는 한편(안미강 및 고대영, 2017), 기업의 신용등급과는 음(-)의 관계를 가진다는(최종서와 노정희, 2016)) 사실이 일관적으로 보고되고 있다. 이런 측면에서 기업의 탄소배출량은 기업에 있어 기후변화에 따른 신용위험을 반영하는 ‘환경부채’로서의 함의를 가진다고 간주할 수 있으며, 이는 결국 재무 지표 중심의 기업 신용등급에도 부정적인 영향을 미칠 것으로 보인다.

2. ESG 성과와 기업 신용등급

근래 들어 기업의 ESG 성과(점수)는 기업과 외부 이해관계자의 정보비대칭을 체계화된 점수 성과를 통해 해소한다는 측면에서 높은 관심을 받고 있다. 이는 기업이 대내외 이해관계자와 효율적인 계약을 이룰 수 있다는 점에서 기업의 지속가능성을 높여주며 이와 동시에 기업 가치가 높아진다는 측면에서

큰 의미를 갖고 있다.

국내 ESG 성과와 신용등급에 대한 연구 결과는 조금씩 혼재되어 있다. 임옥빈 외(2022)는 ESG 종합등급 및 각각의 개별요소의 등급이 높을수록 신용평가등급이 높은 것으로 분석하였다. 이는 신용평가기관이 이와 같은 비재무적 정보 공개의 성과가 정보 비대칭을 낮추고 있는 것으로 판단함을 추측할 수 있는 결과이다. 김광민과 이현상(2021)은 비재무적 정보로서 ESG가 회사채 신용등급 평가에 유의미한 양(+)의 관련성을 증명하였으며, 신용평가기관이 재무 자료뿐 아니라 ESG 등급을 신용평가 등급 산정에 반영하였다는 사실을 확인하였다. 또한 오상희(2021)는 신용평가 정보와 ESG 정보의 기업 가치 관련성을 외국인 지분율을 통하여 검증하였다. 외국인지분율 더미변수를 활용하여 ESG 변수와 기업가치의 관계를 분석한 결과 외국인 지분율이 고려되었을 때 기업의 신용등급이 더 크게 하락한다는 사실을 밝혀냈다.

개별 성과로 봤을 때 ESG 성과는 기업의 특성에 따라 신용등급 및 기업가치에 다른 영향을 끼치고 있다. 전진규(2021)는 국내 신용평가사가 제공하는 신용등급에 개별 ESG 요인이 어떻게 반영되는지 분석하였다. 분석 결과 ESG 요인은 기업의 신용평가에 유의한 양(+)의 영향을 미치는 것으로 나타났는데, 이는 국내 신용평가에 기업의 ESG 요인이 일부 반영된다는 것으로 분석되었다. 특히 지배구조 요인이 기업의 신용등급과 유의한 관계를 나타냈는데, 이는 기업 내 내부통제 장치, 윤리경영 등의 항목 덕분인 것으로 분석되었으며, 대조적으로 환경 및 사회 요인은 신용등급과 부분적으로 유의한 것으로 나타났다. 이정환 외(2022)는 2013년부터 2020년까지 국내 상장기업을 대상으로 ESG 통합 점수, E(환경), S(사회), G(지배구조)로 측정한 사회적 책임 활동이 비대칭적 변동성을 감소시키는지 여부를 검증하였다. 특히 기업을 재벌기업집단과 비재벌기업집단으로 구분함으로써 국내 기업의 특성이 비대칭적 변동성으로 측정한 차기 기업 가치에 영향을 미치는지 여부를 분석하였다. 분석 결과, 환경(E) 성과는 두 기업 집단의 비대칭적 변동성과 음(-)의 관련성을 가졌으며, 사회(S) 성과는 차기 비대칭적 변동성에 유의한 영향을 끼치지 못하는 것으로 나타났다. 이는 환경(E) 성과 공시가 비대칭적 변동성을 줄이는 반면, 사회(S) 성과의 경우 비대칭적 변동성 여부를 밝혀낸 해외

문헌과 상반되는 결과라는 점을 증명하였다.

또한 최금화 외(2021)는 국내 기업을 B2B와 B2C로 구분하였으며, 사회적 책임 활동과 비대칭적 변동성의 관계를 분석하였다. 그 결과 B2B 산업의 사회적 책임 활동과 비대칭적 변동성은 유의한 음(-)의 관계를 가졌으며, 대조적으로 B2C 산업에서는 그 관계가 유의하지 않은 것으로 밝혀졌다.

또 다른 선행연구는 기업의 ESG 등급은 신용평가사가 매기는 기업의 신용등급 향상으로 이어진다는 점을 언급하고 있다. 기업가치 측면에서 봤을 때 신용평가사의 신용등급은 채권 발행 기업의 지급능력을 의미하지만, 이런 지급 능력이 실은 기업의 미래 현금흐름을 내포하고 있다고 할 수 있다(김경옥과 하승화, 2017; 오상희, 2021). 뿐만 아니라 ESG 등급 부여가 기업의 재무 요인뿐 아니라 사회적 책임과 시장 위험을 모두 고려하는 점을 감안하면, 기업의 ESG 성과는 기업의 신뢰도를 높이고 부도 확률은 낮출 것으로 추측해 볼 수 있다. 오상희(2021)는 기업의 ESG 성과 향상에 따른 비용 지출은 기업의 신용등급을 향상시킨다고 주장하였다. 또한 박도준 외(2022)는 ESG 개별 항목과 부도거리로 측정한 신용위험과 관계를 분석하였다. 그 결과 지배구조(G)는 신용위험을 낮추는 것으로 나타났으며, 환경(E)은 신용등급과 신용위험에 모두 영향을 미치지 않는다는 점을 언급하였다. 특히 박도준 외는 일부 신용평가사가 환경(E) 성과를 신용평가에 반영한다는 최근 추세를 언급하며, 추후 시장이 이런 분위기를 반영할 것이라고 기대하였다. 이런 점을 비춰봤을 때 기업의 ESG 성과는 비록 신용평가에 명시되진 않더라도 재무 및 사업 건전성 등 신용평가의 주요 요소에 주요한 영향을 끼치는 것이라고 볼 수 있다.

3. 애널리스트 정보와 기업 신용평가

증권사의 애널리스트는 일종의 정보 중개자로서 기업과 투자자 등 다양한 이해관계자 간의 정보 비대칭성을 줄여줌으로써 자본시장에 유통되는 정보의 효율성을 높이는 기능을 하고 있다(Healy and Palepu 2001). 특히 애널리스트는 리포트 발간 등 다양한 활동을 통해 외부 투자자에 정보를 제공하는

등 자본시장에 긍정적인 기여를 하는 것으로 알려져 있다. 임병권과 박재환(2017)은 애널리스트가 다양한 기업 및 산업 정보를 대중에 제공함으로써 국내 자본시장에 긍정적인 영향을 미친다는 점을 주장하였다. 정석우 외(2011)는 애널리스트는 전문적인 산업 지식을 공급함으로써 외부 투자자와 경영자의 의사 결정에 기여한다는 사실을 언급하였다.

애널리스트의 정보 공급 활동 정도를 나타내는 애널리스트 커버리지가 자본시장에 미치는 영향은 여러 형태로 나타날 수 있다. Lys and Sohn(1990)은 애널리스트 커버리지는 긍정적인 시장반응과 관련성이 있다는 점을 언급하였고, Ayers and Freeman(2003)은 애널리스트 커버리지가 높은 기업은 주가에 미래 이익에 관한 정보가 상대적으로 많이 담겨 있다는 사실을 주장하였다. 국내 연구에선 이재홍과 오명전(2013)이 과잉투자 기업의 애널리스트 커버리지가 낮을 경우 신용등급에 대한 부정적 영향이 더 크다는 점을 증명함으로써 애널리스트의 정보 공급 활동과 정보위험 간의 관련성을 확인하였다.

일부 선행연구에서는 애널리스트 커버리지와 기업 가치의 관계에 있어서 순기능과 역기능을 언급하고 있다. Ellul and Panayides(2018)는 애널리스트 정보가 주식시장에서 유동성을 공급할 뿐 아니라, 기업가치의 기준을 설정하는 순기능이 있다는 사실을 제시하였다. Bradshaw et al.(2009)은 애널리스트의 기업 전망은 낙관적인 측면이 과도하여, 오히려 이것이 기업 가치를 왜곡시키는 측면이 있다는 점을 언급하였다. 또 다른 선행연구는 애널리스트 커버리지가 일정 부분 기업 혁신에 기여한다는 사실을 언급하고 있다. 이승훈과 김수현(2022)은 국내 주식시장에서 애널리스트 커버리지는 연구개발(R&D) 활동을 촉진시키는 점을 언급하였다. 이들은 2003~2012년 국내 애널리스트 커버리지 데이터와 국내 특허 데이터가 정리된 데이터를 분석하여 애널리스트 커버리지와 기업 특허 수 간의 유의미한 양(+)의 관계가 있다는 사실을 도출하였다.

위와 같은 논의를 종합하였을 때 애널리스트는 시장에 정보 공급 활동을 함으로써 기업에 대한 정보 위험을 줄이며, 이는 신용등급 혹은 신용위험으로 측정되는 기업의 신뢰도 향상으로 이어진다고 볼 수 있다. 구체적으로 애널리스트의 긍정, 혹은 부정 전망의 정도를 뜻하는 애널리스트 커버리지가 특정

기업에 낙관적이거나 부정적인 측면을 부각한다면 이는 시장 투자자의 투자 의사 결정에 영향을 끼치는 주요 요소로 작용할 수 있다.

Ⅲ. 표본과 연구 모형

1. 표본과 데이터 구축

본 연구의 분석 표본은 2000년부터 2021년까지 KOSPI 상장 이력이 있는 기업을 분석하였으며 금융기업은 제외하였다. 또한 기업의 특성에 따른 대안 신용평가 모형의 예측력을 검증하기 위하여 기업 샘플을 전체 기업에 더하여 재벌기업집단, 비재벌기업집단으로 구분하여 추가적인 분석을 수행하였다. 그 결과 전체 기업의 기업 숫자는 930개, 관측치는 14,520개에 이르며, 재벌의 경우 242개, 3,224개, 비재벌기업집단의 경우 688개, 11,296개로 나뉜다. 본 연구에 쓰인 분석 표본의 기업 개수와 관측치는 아래 <표 1>과 같다.

<표 1> 기초통계량

	기업 개수	관측치
전체 기업	930	14,520
재벌기업집단	242	3,224
비재벌기업집단	688	11,296

본 연구는 탄소배출 정보(Matsumura et al., 2014; Lee and Cho, 2021; 최종서·노정희, 2016), ESG 성과(Kim et al., 2014; Lee et al., 2021; 최금화 외, 2021), 애널리스트 커버리지(Ayers and Freeman, 2003; Lys and Sohn, 1990; 이승훈·김수현, 2022; 이재홍·오명전, 2013) 등 다양한 선행연구에 언급된 문헌을 참고하여 다양한 재무·거시경제 변수를 산출하였다. 각 데이터의 출처는 기업 재무 데이터와 애널리스트 커버리지 정보의 경우 FN가이드에서 운영하는 데이터가이드에서, 거시경제 변수는 한국은행 경제통계시스템 홈페이지에서 입수하였다. 법인세율, 알트만 Z-점수 등은 회계법인 홈페이지와 관련 문헌을 참고해 작성하였다. 이어 각 기업의 ESG

점수는 ESG 평가기관인 서스틴베스트에서 입수한 통합 및 개별 ESG 평가 점수를 활용하였다. 한국 탄소정보공개프로젝트(CDP)의 연간 보고서에서 탄소배출량 정보는 직접 수집하며, 기업의 직접 탄소 배출량인 scope1과 간접 탄소 배출량인 scope2의 합계를 개별 기업의 탄소배출량으로 활용한다. 기업들은 매년 CDP에 자발적으로 자사의 탄소배출 정보를 제공하여 공시하는데, 이처럼 CDP를 통하여 외부에 공개되는 기업의 탄소배출량은 신뢰성이 높은 것으로 평가된다. 기업이 CDP를 통해 탄소배출 정보를 공시하는 것은 자발적인 선택이지만 CDP의 탄소배출 요청에 우선 응하는 것은 추후 기업이 같은 선택을 내릴 경향이 높은 것으로 알려져 있다(Matsumura et al., 2014; Stanny, 2013; 최종서·노정희, 2016).

〈표 2〉 비재무정보의 분석 기간 및 출처

비재무 정보	연도	출처
탄소배출량	2013~2017년	탄소정보공개프로젝트(CDP)
기업의 ESG 성과	2010~2020년	서스틴베스트
애널리스트 커버리지	2000~2021년	데이터가이드

끝으로 본 연구는 국내 기업의 특성을 고려한 분석을 수행하기 위하여 기업을 재벌기업집단과 비재벌기업집단으로 구분하였다. 재벌기업집단 소속 기업 선정은 공정거래위원회가 매년 지정, 공개하는 상호출자제한기업집단 리스트를 참고하였다. 이와 같은 과정을 거쳐 취합된 각 비재무 정보 데이터의 분석 기간과 출처는 〈표 2〉와 같다.

한편 본 연구에서는 신규 상장 기업 혹은 과거 상장폐지 기업이 누락됨에 따라 발생하는 생존 편향(Survivorship bias) 문제를 해소하기 위하여, 분석 기간에 해당되는 신규 상장기업과 상장폐지 기업을 기업 표본에 모두 포함시켰다. 또한 본 연구는 각 종속 변수와 설명 변수의 극단 값을 1% 수준으로 윈저라이즈(Winsorize)하였다.

이어 본 연구가 머신러닝 및 실증 모형을 분석하기 위해, 시장가치총부채비율(TDM), 총자산대비 영업이익(Profit), 총자산 변화율(Assets), 기업 장기

〈표 3〉 주요 재무 및 거시경제 변수

변수명	산출 방법
종속 변수	
DD	※ 수식 1 참조
비자발적 상폐 여부	비자발적 상폐 시 1, 그 외 0
관심 변수	
CO2	탄소배출량/매출액
E/S/G/ESG	환경·사회·지배구조 점수
애널리스트 커버리지	증권사별 6개월 전 대비 투자여건 점수 Strong Buy=5, Buy=4, Neutral, 3, under Weight =2, Sell=1
재무 변수	
Rating	회사별 신용등급 BB 이상 1, 신용등급 BB 미만 0
TDM	(유동부채 + 장기부채) / 시가총액
Profit	(감가상각전) 영업이익 / 총자산
Assets	총자산 로그값
Mature	기업 데이터가 최근 5년 이상 존재 시 1, 5년 이하 시 0
Mktbk	시가총액 / 총자산
ChgAsset	총자산 (연간) 증감률
Capex	자본지출 / 총자산
Tang	유형자산 / 총자산
RD	연구개발비 / 총매출
Unique	우주선, 유도미사일, 비행기, 컴퓨터, 반도체, 화학 관련 업종 시 1, 그 외 0
SGA	판관비 / 총매출
Cash	현금 및 단기투자자산
Taxrate	법인세 최고세율
Depr.	감가상각비 / 총매출
StockVar	일일 주가수익률의 연간변동성
Zscore	알트만의 Z-점수 ⁴⁾
Stock	연간 주식누적수익률
CrspRet	주식시장의 연간누적수익률
Industlev	TDM 중앙값
industgr	ChgAsset 중앙값
거시경제 변수	
Termsprd	10년물 국채와 1년물 국채의 수익률 차이
inflation	예상물가상승률
Macroporf	비제조 기업의 연간 당기순이익 로그값
Macrogr	실질 GDP성장률
Netpay	(현금배당금 + 보통주 및 우선주 순증액) / 총자산
기타 변수	
Predictive Value	확률예측값
Size	총자산의 상위 30% 기업이면 2, 중간 40%면 1, 하위 30%면 0
Growth	Mktbk 변수 크기가 상위 30% 기업이면 2, 중간 40%면 1, 하위 30%면 0
High-Tech	IT제품 및 서비스 기업이면 1, 그 외면 0

존속 여부(Mature), 시장가-장부가 비율(Mktbk), 총자산 증감률(ChgAsset), 자본지출(CAPEX), 유형자산(Tang), 연구개발비(RD), 특수산업(Unique), 판관비(SGA), 현금성자산(Cash), 법인세율(Taxrate), 감가상각비(Depr), 주가변동성(StockVar), 알트만 Z-점수(Zscore), 신용등급(Rating), 개별 주가수익률(Stock), 시장 주가수익률(Crspret), 부채비율 중앙값(indstlev), 총자산 증감률 중앙값(industgr)을 활용하였다. 자산 더미 변수(Size), 기업 더미(Growth), 첨단기술 더미(Hightech) 역시 활용하여 머신러닝 분석에 이용하였다. 한편 머신러닝 모형을 통해 예측한 낮은 신용등급에 대한 확률값 역시 부도거리 실증 모형의 조절변수로 사용하였다.

한편 머신러닝 모형을 분석하기 위해 활용한 거시경제 변수로는 10년과 1년물 국채스프레드 수익률 차이(termsprd), 예상물가상승률(inflation), 당기순이익 증감률(Macroporf), 실질GDP 성장률(Macrogr), 순배당률(Netpay)을 도입하였다. 각 변수의 구체적인 정의는 <표 3>에서 설명하고 있다.

2. 비자발적 상장폐지 기업 및 부도거리

대안 신용평가 모형에 대한 가능성을 논의하기 위하여 본 연구는 우선 기업의 비자발적 상장폐지 여부와 부도거리(Distance to Default)를 종속변수로 선정하였다. 먼저 상장 폐지는 정리매매 혹은 최종 파산으로 이어져 투자자들에게 가장 큰 손실을 끼칠 수 있는 이벤트라고 할 수 있다. 본 연구는 기업 공시 채널인 KIND를 이용하여, 인수합병과 같이 자발적인 상장폐지 신청 기업을 분석 대상 기업에서 제외하는 방식으로 비자발적 상장 폐지 여부를 정의하였다. 비자발적 상장 폐지 기업의 대다수는 기업의 부실(자본잠

4 신흥국의 경우 파산비율을 뜻하는 Z-점수 계산 방법은 아래와 같다. Meeampol et al.(2014)을 참고함.

$$Z = 3.25 + 6.56X_1 + 3.26X_2 + 6.72X_3 + 1.05X_4$$

$X_1 = (\text{유동자산} - \text{유동부채}) / \text{총자산}$

$X_2 = \text{유동이익} / \text{총자산}$

$X_3 = \text{EBIT} / \text{총자산}$

$X_4 = \text{총자본} / \text{총부채}$

식, 감사의견거절 등)과 관련성이 높은 것으로 확인된다.

일반적인 재무지표 기반의 신용평가 모형은 채권 시장에서 거래되는 회사채를 발행하는 기업을 위주로 평가하고 있다. 대조적으로 감사의견이 거절되거나, 자본이 잠식되었거나, 비자발적으로 상장폐지되거나 최종 부도 결정되는 등 순수한 재무적 사유로 상장 폐지되는 기업들을 별도 대상으로 한 신용평가를 하지 않고 있다.

이와 같은 비자발적 상장폐지 기업을 대상으로 기업 부실 및 재무 성과에 대한 분석이 국내 기업 관련 재무 연구에서 많이 되어 있지 않은 상황이다. 국내 상장사가 워크아웃을 직접 신청하는 경우가 극소수임을 고려해 볼 때, 이러한 비자발적 상장 폐지에 대한 분석은 향후 대안 신용평가 모형이 기업의 신용 리스크를 정확하게 측정하는 데 도움을 줄 수 있다.

본 연구의 연구 기간(2000~2021년) 동안 유가증권 시장 기준으로 비자발적 상장폐지 기업으로 분류된 기업 수는 총 189개이다. 해당 기업들의 연구 기간 내 비자발적인 이유로 상장 폐지되었으며, 분석에 있어서는 상장폐지와 가장 가까운 회계연도를 기준으로 분석하였다. 이는 최근 회계자료로부터 상장폐지까지 기간이 1년 이상 소요된 경우를 반영한 것이다. 널리 알려진 대표적 비자발적 상장폐지 기업은 넥솔론(태양공 제조업체), 대아리드선(기초소재), 베네데스하이텍(핸드백 제조업체), 사조해표(식음료 제조업체), 코리아오토글라스(자동차 안전유리 제조업체), 한진해운(해운업체), STX조선해양(조선업체) 등으로 그 업종과 규모가 다양하다.

특히 본 연구는 비자발적 상장폐지 기업으로 분류된 기업들에 대해 기존의 국내 신용평가사 모형이 잘 예측하는지 판단하기 위해 기업의 상장폐지 시점에 대해 가장 최근접 회계연도를 기준으로 하여 분석하였다. 이는 상장폐지가 된 후 공시의무가 사라져 더 이상 회계 정보를 활용할 수 없는 상황에 기인한다.

본 연구에서는 신용위험 측정을 위하여 Merton(1974)이 소개한 부도거리(Distance to default)를 계산하였다. 부도거리는 시장에서 거래되는 주식이 격과 수익률의 변동성에 기반하여 신용위험을 측정할 값을 말한다. 구체적으로 총자산의 시장가치와 부채의 차이를 총자산의 변동성으로 나누어 산출한 값이다. Merton(1974)은 채권 만기 도래 시 주주가 채권을 상환하고 남은

자산을 소유하기 때문에, 자본은 콜옵션과 같은 성격을 갖고 있다고 밝힌다.

이 부도거리 값(DD)은 기업의 부도 가능성을 부도 확률로부터 역산한 거리를 나타낸 것으로서 그 값이 크면 부도 가능성이 낮은 기업이며, 그 값이 작으면 부도 가능성이 낮은 기업이라고 할 수 있다. 구체적인 식은 아래 수식 1과 같다.

$$DD = \frac{\ln\left(\frac{V}{L}\right) + \left(\mu - \frac{\sigma_V^2}{2}\right)(T-t)}{\sigma_V \sqrt{T-t}} \dots (1)$$

위 식에서 총자산의 시장가치(V)는 각 기업의 연도별 시가총액(E)과 부채의 만기상환액(L)을 합산하여 계산하였다. 식(1)에 따르면 기업의 레버리지 비율이 작을수록(L/V), 그리고 기업가치의 변동성이 작을수록 기업의 부도거리가 증가하게 된다. 부채의 만기상환액(L)은 Vassalou and Xing(2004)과 Bharath and Shumway(2008)의 방법을 참고하여, 유동부채 전체와 비유동부채의 50%를 합산하였다. 무위험이자율은 1년 만기(364일) 통안증권 금리를 사용하였다. 기업의 시장가치의 변동성 σ_V 은 개별 기업 주식의 52주 주간 변동성을 기준으로 측정하였다. 1년 동안 부도가 일어날 수 있는 지표를 고려하여 (T-t)는 1년으로 고정하였다.

3. 머신러닝 모형

본 연구는 기업의 부실 위험에 대한 분석에 앞서, 머신러닝 모형을 활용하여 현재 신용 평가사가 활용하는 신용 등급 산출 로직을 재구성해보고자 한다. 이를 위해 기업의 투자적격등급(BBB) 이상과 이하에 대한 기업을 구분하여 투자적격등급 아래의 경우는 1을, 투자적격등급 이상의 기업의 경우에는 0을 부여하는 지시변수를 바탕으로 머신러닝 모형을 분석하였다.

모형 분석을 수행하기 위하여 본 연구는 2000~2021년 사이 국내 상장기업을 대상을 분석하였으며, 이진 분류(Binary Classification)에 성과가 높은

랜덤 포레스트, 그래디언트부스팅디시전트리(GBDT)와 같은 머신러닝 알고리즘을 사용하여 예측 성과를 비교 분석하였다. 추가적으로 모형의 적합도를 기존 방식들과 분석하기 위하여 로지스틱 회귀 모형을 비교군으로 사용하였다. 머신러닝 분석을 위한 train set은 2000년부터 2015년까지, test set은 2016년부터 2021년도까지로 구분하여 반영하였다.

본 연구는 머신러닝 분석에 앞서, 그리드 서치(grid search)를 통하여 다양한 하이퍼파라미터 튜닝(hyperparameter tuning)을 실시하였다. 하이퍼파라미터 튜닝은 모형에 임의의 값들을 넣어 더 나은 결과 값을 찾기 위한 것이다. 본 연구는 하이퍼파라미터 튜닝을 통해 최적의 값을 모형에 부여하는 모델링 과정을 반복하였다. 하이퍼파라미터 튜닝은 하이퍼파라미터를 통해 만들어진 조합 모두에 대해 모델링하며, 이에 대하여 최적의 결과가 나오는 조합을 알려주는 기능을 한다.

본 연구는 로지스틱 및 머신러닝 분석에 쓰이는 데이터가 불균형한 점을 감안하여 성능 평가 점수로 활용한 f-1 score와 가중치(w)를 제외한 모수에 대하여 그리드서치를 수행하였다. class별 가중치는 0의 경우 0.6353, 1의 경우 2.3466이다. 본 연구가 King and Zeng(2001)을 참고하여 해당 가중치 값을 도출한 수식은 아래와 같다.

$$w_0 = (1 - \tau) / (1 - \bar{y})$$

$$w_1 = \tau / \bar{y}$$

위 수식에서 w_0 은 투자적격등급 이상 기업(class 0)에 대한 가중치, w_1 은 투자적격등급 이하 기업(class 1)에 대한 가중치를 뜻한다. 또 각 식에서 τ 은 모집단의 비율에 대한 사전 정보를 기반으로 한 추정치를 뜻하며, \bar{y} 은 각 샘플에서 관찰된 비율(샘플링 확률)을 의미한다.

이어 본 연구는 로지스틱 모형을 소개하고자 한다. 일반적인 로지스틱 모형 예측 변수인 y_i 의 값이 {0, 1}를 취하도록 하며, 예측된 로지스틱 모형은 1을 Positive class, 0을 Negative class로 분류한다. 이를 위해 로지스틱

함수를 사용하며, 모형의 예측 확률인 $P(y_i = 1|X_i)$ 은 다음 식으로 표현될 수 있다.

$$\hat{p}(X_i) = \text{expit}(X_i\beta + \beta_0) = \frac{1}{1 + \exp(-X_i\beta - \beta_0)}$$

위 수식에서 X_i 는 각 독립 변수를 의미하며, β 는 회귀계수, β_0 는 절편을 의미한다. 본 연구는 최적화 문제를 해결하기 위하여 정규화를 의미하는 $r(w)$ 를 취한 이산 로지스틱 분석을 도입하였다. 로지스틱 회귀 모형의 확률 예측력을 검증하기 위하여, 본 연구는 속성들의 계수와 절편을 확인하였고, 손실 역시 고려하였다. 다시 말해, 모형의 적합성을 평가하기 위하여 각 데이터 샘플의 손실, 즉 모델 예측의 비적합성 여부를 계산한 이후 이를 평균화하였다. 손실 여부를 고려한 로지스틱 회귀, 즉 손실 함수는 다음과 같은 수식을 취하고 있다.

$$\min_w C \sum_{i=1}^n \left(-y_i w_1 \log(\hat{p}(X_i)) - (1 - y_i) w_0 \log(1 - \hat{p}(X_i)) \right) + r(\beta)$$

위 수식에서 y_i 는 종속 변수를 의미하며, $r(\beta)$ 은 과적합을 방지하기 위한 정규화(regularization)를 뜻한다.

이어 본 연구는 첫 기계학습 알고리즘 모형인 랜덤포레스트 모형을 소개하고자 한다. 앙상블 기반 머신러닝 모형인 랜덤포레스트는 분류와 회귀분석이 모두 가능하다. 랜덤 포레스트의 포레스트는 숲(Forest)을 뜻하며, 결정 트리의 트리는 나무(Tree)를 의미한다. 즉, 나무가 모여 숲을 이루듯이, 데이터가 입력된 결정 트리(Decision Tree)가 모여 랜덤 포레스트(Random Forest)를 구성하는 것이다. 구체적인 원리는 다음과 같다. 랜덤포레스트는 새로운 데이터를 다양한 결정 트리에 입력시키며, 각 결정 트리가 분류한 결과에서 가장 많이 득표된 결과(hard voting)가 최종적인 분류 결과로 선정된다(Altman and Krzywinski, 2017; Leo, 1996; Leo, 2001). 랜덤포레스트 모형의

가장 큰 장점은 일부 결정 트리에서 발생할 수 있는 과적합 문제를 예방할 수 있다는 것이다. 따라서 랜덤포레스트의 주요 기능은 무수히 많은 수의 트리를 생성해냄으로써 최종적인 분류 결과가 과적합 값이 되지 않도록 예방하는 데 있다.

본 연구는 랜덤포레스트 모형 구축을 위해 N 규모의 샘플을 train data(표본 내 데이터)에서 추출한 뒤 부트스트랩을 진행하였다. 부트스트랩이란 데이터셋의 샘플링 방식으로, 모형이 데이터에서 추출된 서로 다른 학습데이터셋을 기반으로 복원추출을 하여, 원 데이터 수만큼 데이터 셋을 뽑는 과정을 말한다. 이후 본 연구는 종속 변수의 라벨이 카테고리형{0,1}이란 점을 고려하여 다수결의 원칙에 따라 가장 많이 예측된 클래스값을 최종값으로 하였다. 그 결과는 수식 $\hat{C}_{rf}^P(x) = \text{majority vote } \{\hat{C}_b(x)\}_1^B$ 과 같다.

다음으로 본 연구는 두 번째 기계학습 알고리즘 모형인 그래디언트부스팅트리(GBDT)를 도입하고자 한다. GBDT의 기반이 되는 그래디언트부스팅머신(GBM)은 회귀, 분류 모델에 모두 활용 가능하다. 또한 랜덤포레스트와 같이 여러 결정 트리를 묶어 강력한 예측 모델을 만드는 앙상블 머신러닝 모형으로 꼽힌다. 그래디언트부스팅트리(GBDT)의 특징은 상대적으로 얇은 결정 트리를 무수히 많이 연결한다는 것이다. 각 트리가 일부 데이터만을 잘 예측하는 특성을 가진 만큼, 트리가 많이 추가된 모형은 그만큼 성능이 크게 개선된다는 특징을 갖고 있다. 다만 랜덤포레스트와 차이점은 현 트리가 이전 트리의 예측값과 타깃값 사이의 오차를 줄이는 방향으로 형성되는 알고리즘이라는 것이다. 이를 위해 GBDT는 경사하강법(gradient descent)을 사용해 추가되는 새로운 트리의 예측 값을 보정한다. 이러한 분석 과정에서 GBDT는 무작위성이 발생하지 않으며, 강력한 사전적인 가지치기 기능을 사용함으로써 빠른 예측 능력을 자랑한다.

또한 GBDT는 손실 함수를 줄이는 분류 기반 모형이다. 여기서 손실함수는 머신러닝의 지도학습 시 알고리즘이 예측한 값과 실제 값의 차이를 비교하는 함수를 말하며, 알고리즘이 얼마나 잘못 예측하는지 정도를 의미한다. 즉, GBDT는 손실함수가 최소가 되는 지점으로 집중적으로 학습해나가는 결정 트리 기반 알고리즘이라고 할 수 있다.

이러한 과정을 거쳐 머신러닝 모형이 학습되면 신용평가사가 예측하는 기업의 부실화 정도를 나타내는 부실 확률 예측값(Predictive value)을 구할 수 있다. 만약 머신러닝 모형의 추정 성과가 우수하다면 이러한 확률값은 현재 기업의 부실화 정도를 신용평가사에서 판단하는 연속적인 변수로 고려될 수 있다. 특히 신용평가사의 신용 등급 정보가 채권을 발행하는 기업들 위주로 간행이 연속적으로 되지 않고 있는 점들을 고려해 볼 때, 이러한 예측 확률값을 조절 변수로 사용하여 대안 신용 모형에서 다양한 변수들을 보다 넓은 표본에서 고려할 수 있다. 기업의 확률 예측값을 연도별로 추정하고 이를 패널 회귀 분석의 통제 변수로 활용하기 위해서다. 보다 정밀한 분석을 위하여 본 연구는 변수 중요도와 머신러닝 예측 성능까지 모두 분석해보고자 한다.

4. 부도거리 분석 모형

탄소배출량, ESG 성과, 애널리스트 커버리지 정보 등이 신용 등급 이외에 기업의 부실에 추가적으로 미치는 영향을 분석하기 위해 패널 회귀 분석 모형을 이용하였다. 종속변수로는 이미 언급한 부도거리로 설정하였다. ESG 성과와 부도거리의 관계를 나타내는 실증 모형은 다음과 같이 표현된다.

$$DD_{i,t+1} = \alpha + \beta_0 \cdot E_{i,t} + \beta_1 \cdot S_{i,t} + \beta_2 \cdot G_{i,t} + \gamma \cdot X_{i,t} + \varepsilon_{i,t}$$

여기서 DD는 t년도 회계연도를 기준으로 1년 뒤인 t+1년도의 부도거리를 나타낸다. 환경(E), 사회(S), 지배구조(G) 점수에 대한 분석을 기본으로 하였으며, 전체 3부분을 다 포함하거나 ESG 총점만 독립변수로 구성한 실증 모형 분석 역시 수행하였다. 개별 기업들의 부도거리 특성을 반영하기 위해서 기업 고정효과 및 시간 고정효과 역시 회귀모형 분석에 추가하였다.

본 모형에서 조절변수로는 머신러닝 모형에서 예측한 신용등급 확률값을 사용하였다. 추가로 로그화된 총자산, 장부 레버리지 비율, 산업 레버리지 비율, 고정 자산 비율, 영업이익률(ROA), 기업의 부실을 표현하는 Altman의 Z 점수 역시 포함하였다. 산업 터미 변수 대신 산업 평균 레버리지 비율을

통해 산업간 차이가 가져올 수 있는 부도거리의 변동(Variation)을 보다 명확히 설명하였다.

탄소배출량과 부도거리의 관계는 ESG 정보와 유사하게 다음과 같이 모형화하였다. ESG정보 대신 탄소를 독립변수로 추가하였으며, 관련 기업 변수와 고정효과를 모형에 추가하였다.

$$DD_{i,t+1} = \alpha + \beta \cdot CO_{2\ i,t} + \gamma \cdot X_{i,t} + \varepsilon_{i,t}$$

끝으로 본 연구는 애널리스트 커버리지와 부도거리의 관계를 다음과 같이 설정하고자 한다. 표본이 부족한 탄소데이터와 달리 애널리스트 커버리지에 대해서는 E, S, G를 조절한 모형과 조절하지 않은 모형 두가지에 대해서 모형을 예측하였다.

$$DD_{i,t+1} = \alpha + \beta \cdot annalyst_{i,t} + \gamma \cdot X_{i,t} + \varepsilon_{i,t}$$

$$DD_{i,t+1} = \alpha + \beta \cdot annalyst_{i,t} + \delta_1 E_{i,t} + \delta_2 S_{i,t} + \delta_3 G_{i,t} + \gamma \cdot X_{i,t} + \varepsilon_{i,t}$$

이는 애널리스트 커버리지가 기업의 ESG 경영활동 관련 추가적인 정보를 전달하여 분석될 가능성을 고려한 것이다.

IV. 연구 결과

1. 머신러닝 성과

앞서 언급한 바와 같이 본 연구는 투자적격 등급(BBB) 이하 등급 1, 그렇지 않은 채권 등급을 0으로 구분하여 전통적 로지스틱 분석 및 랜덤포레스트와 그래디언트부스티드디지전트리를 사용한 머신러닝 모형의 성과 분석을 수행하였다.

본 예측 성과 분석에 앞서 <그림 1, 2>에서는 랜덤포레스트와 그래디언트부스티드디지전트리(GBDT)로 분석한 변수별 중요도를 표시하였다. 변수별 중요도는 Permutation Importance 방식을 활용하였다. Permutation Importance는 모델 예측에 있어 가장 큰 영향력이 큰 변수(Feature)를 포착하는 방법으로 꼽힌다. 본 연구는 각 머신러닝 모형 훈련 이후 Permutation Importance를 모형별로 추출하였으며, 훈련된 모델이 특정 Feature를 쓰지 않았을 때 이것이 성능 손실에 얼마나 큰 영향을 주는지 여부를 Feature의 중요도를 통해 파악하였다. Permutation Importance의 가장 큰 장점은 변수별 특정 Feature를 무작위로 섞음으로써(Permutation), 특정 Feature를 노이즈로 만드는 것이다.

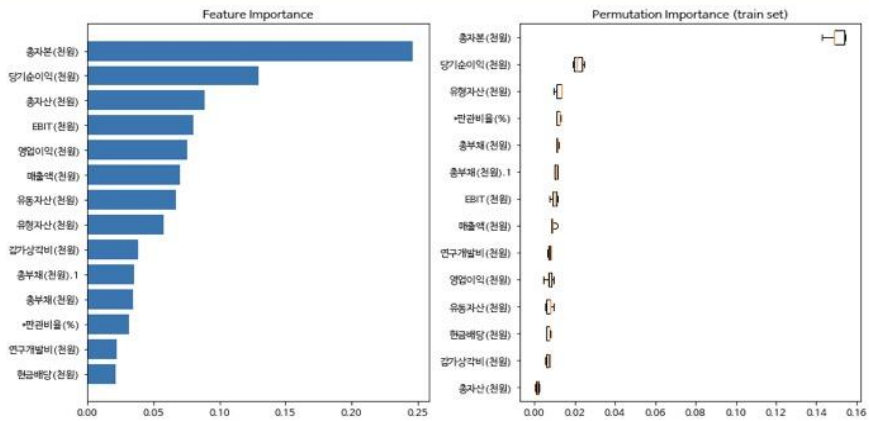
이와 같은 과정을 거쳐 분석한 변수별 중요도는 특정 변수가 제외될 경우 발생하는 모형의 혼잡도 증가로 측정된다. 여기서 혼잡도는 구분된 이후 데이터 집합의 혼잡도를 의미하는데 서로 다른 데이터가 섞여있으면 데이터의 혼잡도 지수인 엔트로피가 높고 같은 값을 위주로 되어 있으면 혼잡도가 낮아지게 된다. 실제 의사결정 나무 모형의 분화 역시 이러한 혼잡도 기준으로 이루어지게 된다.

한편 그림에서 랜덤포레스트 모형의 중요성 평가의 경우 총자본, 당기순이익, 총자산, EBIT, 영업이익, 그리고 GBDT의 경우 총자본, 당기순이익, 유동자산, 판관비율, 매출액 순인 것으로 나타났다. 기업의 순수익, 기업 규모, 수익성 등이 기업의 투자 적격 등급 구분에 있어서 유의미한 것으로

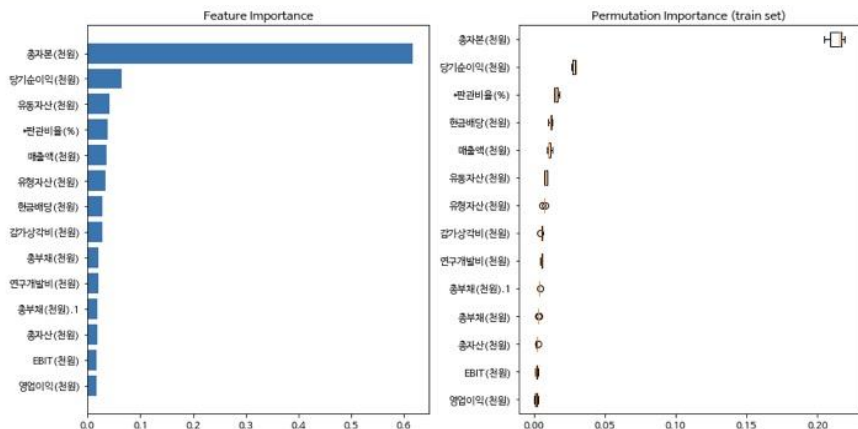
나타나 실제 경제적으로 생각하는 기업의 부실 위험과 일관된 결론을 얻을 수 있었다.

한편, 본 연구는 이진 분류에서 성능 지표로 잘 활용되는 Confusion Matrix 분석을 수행하였다. 이는 학습된 분류 기반 머신러닝 모델이 예측 시 얼마나 confusion(혼란)한지 나타내며, 모형의 정확도(Accuracy)를 알려주는 지표이다. 정확도는 실제와 예측 데이터를 비교 시 두 데이터가 얼마나 동일한지

〈그림 1〉 랜덤포레스트로 추정한 기업 투자 등급에 대한 변수 중요도



〈그림 2〉 GBDT로 추정한 기업 투자 등급에 대한 변수 중요도



판단할 수 있다. 다시 말해, 머신러닝 모형의 이진 분류 상 정확도를 살펴보면 예측 오류가 얼마나 심각한지뿐만 아니라, 무슨 예측 오류가 발생하는지 여부도 알려준다고 할 수 있다. 머신러닝 및 로지스틱 모형의 정확도를 알려주는 수식은 다음과 같다.


$$Accuracy = \frac{correct\ predictions}{all\ predictions} = \frac{TP + TN}{TP + TN + FP + FN}$$

위 수식에서 TP, TN, FP, FN은 각각 True Positive, True Negative, False Positive, False Negative를 뜻한다. 즉, 투자적격 등급(BBB) 이하 등급 1, 그렇지 않은 채권 등급이 0일 때 True Positive(TP)는 0을, True Negative는 1을 정확하게 예측한 값을 의미한다. 즉, 정확하게 예측한 두 값(TP, TN)의 합을 전체 예측 값으로 나눈 값을 정확도라고 부르는 것이다.


본 연구는 로지스틱 모형과 랜덤포레스트, GBDT 모형의 confusion matrix를 train set과 test set을 대상으로 구현하였다. 이에 대한 결과는 다음 <그림 3>, <그림 4>, <그림 5>(이하 train set), <그림 6>, <그림 7>, <그림 8>(이하 test set)과 같다. 먼저 Train Set의 경우 <그림 3>의 로지스틱 모형의 경우 True Positive와 True Negative의 합의 비율은 81.7% ((1750+561)/2769)로 나타났으며, 이는 <그림 4>의 랜덤포레스트의 98.0% ((2139+575)/2769), <그림 5>의 GBDT의 97.9%(2166+544)/2769)보다 낮았다. 결국 confusion matrix를 통한 정확도 예측은 머신러닝의 랜덤포레스트가 가장 성능이 뛰어나다고 평가할 수 있다.

이어 Test Set의 경우 <그림 6>의 로지스틱 모형의 경우 True Positive와 True Negative의 합은 91.3%((870+226)/1201)로 나타났으며, 이는 <그림 7>의 랜덤포레스트의 93.01%((957+170)/1201), <그림 8>의 GBDT의 92.8%(958+159)/1201보다 낮았다. Train set과 유사하게 confusion matrix를 통한 정확도 예측 역시 머신러닝의 랜덤포레스트가 가장 성능이 뛰어난 것으로 나타났다.


〈그림 3〉 로지스틱 모형으로 추정한 투자 등급에 대한 confusion matrix(train set)




〈그림 4〉 랜덤포레스트로 추정한 투자 등급에 대한 confusion matrix(train set)




〈그림 5〉 GBDT로 추정한 투자 등급에 대한 confusion matrix(train set)




〈그림 6〉 로지스틱 모형으로 추정한 투자 등급에 대한 confusion matrix(test set)



〈그림 7〉 랜덤포레스트로 추정한 투자 등급에 대한 confusion matrix(test set)



〈그림 8〉 GBDT로 추정한 투자 등급에 대한 confusion matrix(test set)



또 본 연구는 전통적인 로지스틱 모형과 기계학습 알고리즘인 랜덤 포레스트, GBDT를 통하여 기업의 투자 등급(BBB)에 대한 예측 성능을 train set과 test set을 대상으로 분석하였다. train set을 대상으로 분석한 결과는 아래 <표 4>, <표 5>, <표 6>에 정리되어 있다. 각 표는 앞서 수식을 기반으로 한 모형별 정확도(Precision)를 비롯하여, 재현율(Recall Score), F1 점수(F1 Score), 서포트(Support) 값들이 보고되어 있다. 정밀도는 머신러닝 모델이 특정 값을 Positive로 예측했을 경우 그 값이 실제로 Positive인 비율을 말하며, 재현율이란 실제 Positive인 값을 정확하게 Positive로 맞춘 비율을 의미한다. 또한 F1 점수는 앞서 정밀도와 재현율의 조화 평균 값을 의미하는데, 분류 클래스 간의 데이터 불균형이 심할 때 확인할 수 있는 지표이다. 서포트 값은 본 연구에서 활용한 데이터셋에서 관찰된 각 분류 클래스 숫자를 말한다.

<표 4> 신용 등급에 대한 예측 성능 - 로지스틱 모형(train set)

index	precision	recall	f1-score	support
0	0.98323	0.78017	0.87001	2179
1	0.53942	0.95085	0.68834	590
accuracy			0.81654	2769
macro avg	0.76133	0.86551	0.77918	2769
weighted avg	0.88866	0.81654	0.83130	2769

<표 5> 신용 등급에 대한 예측 성능 - 랜덤 포레스트(train set)

index	precision	recall	f1-score	support
0	0.99304	0.98164	0.98731	2179
1	0.93496	0.97458	0.95436	590
accuracy			0.98014	2769
macro avg	0.96400	0.97811	0.97083	2769
weighted avg	0.98066	0.98014	0.98029	2769

<표 6> 신용 등급에 대한 예측 성능 - GBDT(train set)

index	precision	recall	f1-score	support
0	0.97920	0.99403	0.98656	2179
1	0.97666	0.92203	0.94856	590
accuracy			0.97869	2769
macro avg	0.97793	0.95803	0.96756	2769
weighted avg	0.97866	0.97869	0.97847	2769

각 표를 살펴보면 투자적격 등급과 투자적격 이하 등급을 예측하는 데 있어 차별적인 효과가 발생하고 있다는 점을 알 수 있다. 먼저 로지스틱 모형의 경우 투자 적격에 대해서는 98.32% 가량의 예측 성과를 보이지만 투자 비적격 등급에 대해서는 53.94%로 성능이 크게 감소한다. 반면 랜덤포레스트와 그래디언트부스티드디시전트리(GBDT) 모형의 정확도(precision) 예측 성능은 각 99.30%, 97.92%로 성과도 높을 뿐만 아니라 투자 적격 등급 및 투자 부적격 등급 예측에 있어서 큰 차이를 보이고 있지 않다.

다음으로 test set을 대상으로 분석한 결과는 아래 <표 7>, <표 8>, <표 9>에 정리되어 있다. 앞서 <표 4>, <표 5>, <표 6>과 마찬가지로 로지스틱 모형의 경우 예측 성과는 투자적격 등급과 투자적격 이하 등급에 있어 차별적인 효과가 발생하고 있다. 그러나 로지스틱 모형의 투자 적격에 대한 예측 성과는 98.31%로 train set 분석과 비슷한 수준이었지만, 투자 비적격 등급에 대해서는 71.52%로 train set 분석(53.94%)에 비하여 개선되었다는 사실을 알 수 있다. 또한 랜덤포레스트와 그래디언트부스티드디시전트리(GBDT) 모형의 정확도(precision) 예측 성능은 각 92.23%, 91.94%로 train set 분석과 비슷한 수준의 예측 성능을 보이고 있다.

<표 7> 신용 등급에 대한 예측 성능 - 로지스틱 모형(test set)

	precision	Recall	f1-score	support
0	0.98305	0.90625	0.94309	960
1	0.71519	0.93776	0.81149	241
accuracy			0.91257	1201
macro avg	0.84912	0.922	0.87729	1201
weighted avg	0.9293	0.91257	0.91668	1201

<표 8> 신용 등급에 대한 예측 성능 - 랜덤 포레스트(test set)

	precision	recall	f1-score	support
0	0.92278	0.99583	0.95792	960
1	0.97576	0.66805	0.7931	241
Accuracy			0.93006	1201
macro avg	0.94927	0.83194	0.87551	1201
weighted avg	0.93341	0.93006	0.92484	1201

〈표 9〉 신용 등급에 대한 예측 성능 – GBDT(test set)

	precision	recall	f1-score	support
0	0.91939	0.99792	0.95704	960
1	0.98742	0.65145	0.785	241
accuracy			0.92839	1201
macro avg	0.9534	0.82468	0.87102	1201
weighted avg	0.93304	0.92839	0.92252	1201

이러한 성적은 비선형 결합을 통해 예측을 하는 머신러닝 모형들의 특성이 반영된 것으로 보인다. 즉 일반적인 선형결합에 로지스틱 함수를 적용하는 로지스틱 모형과 달리 머신러닝 모형들은 하이퍼 파라미터 값에 따라 다양한 비선형 변환을 할 수 있으며 이러한 지표 관련 비선형적인 성격들이 등급이라는 이산화된 결과값을 설명하는 데 있어서 유용한 결과를 얻을 수 있다고 생각한다.

한편 머신러닝 모형들에 있어서 이와 같이 매우 우수한 예측 성과는 머신러닝을 통해 학습한 모형이 현재 신용평가사의 등급 예측을 매우 유사하게 복원할 수 있음을 시사한다. 이에 따라 이러한 점수를 통해 신용 평가사의 신용등급 패턴을 등급이 없는 기업에도 확장 적용하여, 신용 평가사 평가의 타당성을 분석해 보거나 혹은 조절 변수로 사용하여 신용 등급의 영향을 조절해 보는 것이 가능할 것으로 사료된다. 특히 많은 경우 신용 등급이 있는 회사들이 채권을 실제 발행하는 우량한 기업임을 고려해 볼 때, 우량하지 않은 기업들에 대해 신용 평가 논리를 적용해 가상적으로 시뮬레이션해 볼 수 있는 좋은 방법론이 될 수 있을 것으로 생각된다.

2. 비자발적 상장 폐지 기업 분석

본 절에서는 1절에서 학습한 머신러닝 모형이 비자발적 상장 폐지 상황을 잘 구현하고 있는지 분석하고 관련 시사점을 분석해 보고자 한다. 이를 위해 비자발적인 상장폐지 기업에 대해, 비자발적 상장폐지가 확인된 날짜로부터 가장 최근 회계연도를 기준으로 비자발적 상장폐지 기업에 대해 머신러닝

모형을 적용하여 기존 신용평가사 관점에서 분석하는 부실 정도를 측정해 보았다.

비자발적 상장 폐지는 기업 경영에 있어서 부실 상황이 나타나는 매우 극단적인 이벤트라고 할 수 있다. 재무적인 성과가 부실하여 자본잠식이 우려되거나 이에 따라 외부 감사인들이 의견을 거절하는 심각한 상황이라고 할 수 있다. 실제 이러한 비자발적 상장폐지와 관련하여 기업의 최종 부도로 까지 이어졌던 사례 역시 다수 확인되고 있다.

1절의 분석 결과는 랜덤포레스트나 그래디언트부스티드디시전트리 모형에 있어서 커다란 예측성과의 차이가 나오지 않는 것을 확인하였다. 이에 따라 본절에서 사용하는 부실 확률 예측 문제에서 일반적으로 보다 보편적으로 사용된다고 할 수 있는 랜덤 포레스트 모형을 바탕으로 부실 확률을 예측하였다.

다음 <표 10>에서는 비자발적 상장폐지를 한 기업과 그렇지 않은 기업간에 있어서 머신러닝 모형에서 확인할 수 있는 부실확률 예측값의 분포를 측정한 것이다.

<표 10> 부실 예측 확률 통계량

통계량	전체표본	비자발적 상장폐지
최소값	0.000	0.384
1분위	0.029	0.777
중위수	0.202	0.949
3분위	0.706	0.984
최대값	0.999	0.999
평균	0.355	0.880
표준편차	0.355	0.1326

실제 비자발적 상장 폐지 기업 중에서 BBB 등급 이하로 구분되지 않는 기업은 확률 38.4%를 나타낸 삼에인더스의 경우였으며, 이는 일반적인 상황이 아닌 “이용호 게이트” 관련 범죄와 연루되어 외부감사인의 의결 거절이 나온 매우 특수한 케이스로 알려져 있다. 실제로 이외의 상장폐지 기업들은 예측 확률을 고려한 경우 모두 BBB 등급 아래의 점수를 받은

것으로 확인되고 있다.

심지어 삼에 인더스와 같은 특수한 경우를 포함한다고 할지라도 비자발적 상장폐지 기업은 평균 88.0%로 BBB이하 등급으로 예측되었다. 특히 분위수 차원에서 예측확률의 중위수가 이미 95%로 부실 기업을 잘 예측한다고 할 수 있다. 전체 표본을 보았을 때 3분위수가 70.6%임을 고려해 본다면 현재 신용평가사가 사용하고 있는 예측 모형의 부실 예측 성과가 우수하다고 할 수 있다.

일반적으로 기업의 부실이라는 것은 부정적인 재무 성과의 점진적 누적으로 이루어지는 경우가 대다수라고 할 수 있다. 이에 따라 상장폐지 이전부터 상장폐지까지 점차적으로 기업의 부실화가 심해지는 것이 보다 일반적인 상황이라고 할 수 있다.

〈표 8〉에서는 이러한 상장 폐지 기업에서 상장폐지 이전부터 상장폐지까지 실제로 예측되는 부실 확률이 증가하고 있는지 검토해 보았다. 즉 상장폐지와 가장 가까운 회계연도를 기준으로 그 이전 4년간 부실 확률 변화를 측정하여 다음 〈표 11〉과 같이 요약하였다.

〈표 11〉 상장폐지 기업의 부실 확률 변화

기간	4년 전	3년 전	2년 전	1년 전	0년
부실확률 평균	0.774	0.787	0.829	0.853	0.880

〈표 8〉의 결과는 현재 신용평가 모형이 상장 폐지 기업에의 부실화 정도를 시계열 관점에서 역시 잘 나타내고 있음을 시사한다. 즉 4년 전에 평균 부실 확률이 이미 77.4%이며 1년 전에서는 85.3% 수준으로 예측하여, 평균값이 점증적으로 증가하고 있는 양상을 보이고 있다.

이러한 시계열 변화 양상은 기존 신용평가사의 신용평가가 부실 기업들을 잘 식별해 낼 수 있음을 나타내고 있다. 이미 언급한 바와 같이 비자발적 상장 폐지는 기업의 재무적인 부실을 나타내는 극단적인 이벤트라고 할 수 있으며, 머신러닝 모형으로 재현한 기존의 신용평가 모형은 이와 같은 상황을 잘 반영하고 있는 것으로 나타내고 있다.

한편 이와 같은 결과는 대안 신용평가 모형에 대해서 중요한 시사점을 준다고 할 수 있다. 우선 재무제표 분석에 기반한 기존 신용 평가 모형의 시뮬레이션 결과에서 확인할 수 있듯이 기업이 실제 부실로 이어지는 극단적인 상황은 재무지표의 부정적인 성과가 매우 직접적으로 연관이 된 사건으로 봐야 된다는 것이다. 채무 불이행 및 유동성 문제라는 기업 부실 문제의 최종적인 성격상, 이러한 최종적인 부실 확인 자체는 재무적인 요소가 중심이 되는 기업 경영상의 사건으로 분류되는 것이 타당하다.

다시 말해 대안신용 모형에 사용될 수 있는 다양한 요소들은 외부환경 변화나 기업 경영 변화가 실제 기업의 재무적인 부실까지 이어지는 단계에서 조절하는 역할을 해야 할 것으로 판단된다. 즉 경영학 모형에서 많이 사용되는 조절효과 모형(moderating effect model)에 있어서 조절 변수로서 역할을 해야 되는 것으로 판단된다.

3. 대안신용 정보와 부도거리 분석

ESG 정보 분석

본 절에서는 부도거리와 ESG 정보, 애널리스트 커버리지, 탄소배출 정보와의 관계를 분석하여 대안 신용 모형에 대한 향후 시사점을 찾으려고 한다.

우선 기업별 고정효과 및 시간 고정효과까지 고려한 패널 회귀 모형을 통해 부도거리와 ESG 정보와의 관계를 고려하였다. 기업의 규모, 레버리지, ROA, 토빈의 Q 같은 다양한 기업 변수 이외에도 기존 신용평가 모형에서 투자 비적격 등급 아래를 예측하는 확률을 표현한 “부실 변수”를 추가하여 기존 신용등급에 대한 영향력을 포괄적으로 고려하였다.⁵⁾ 실제 ESG 등급이 있는 기업-회계연도 관측치 중에 실제 신용등급이 있는 기업들은 약 24.5%로서 신용 등급이 있는 기업들에 대해서만 분석을 수행할 경우 표본의 대표성에

5 실제 기업 신용 등급을 이용하여 이러한 분석을 수행할 수도 있지만 채권을 한정적으로 발행하는 국내 자본시장의 상황상 표본에 많은 축소가 있는 것으로 확인된다. 신용 등급을 직접 활용한 분석에서 역시 전반적인 결론의 강건성은 확인할 수 있다.

상당한 손실을 입을 수 있는 상황이다.

〈표 12〉에서는 ESG 정보와 부도거리와의 관계를 전체 표본에 대해서 분석하였다. 표본 기간 내의 ESG 정보가 유가시장 상장사 전체에 제공되는 것이 아니라 일부 기업들만 제공하고 2010년 이후에 데이터가 본격 제공되기 시작했으므로 표본의 숫자가 5915개로 감소하였다. 그러나 KOSPI 상장사에 대해서는 기본적으로 ESG 점수를 공표하는 서스틴베스트의 정책에 따라 전체 표본 기간내 377개의 관측치만 결측치로 확인되었다.

〈표 12〉 ESG 정보와 부도거리: 전체 표본

독립변수	부도거리				
ESG 점수	-0.001 (-0.3)				
E 점수		-0.010*** (-4.2)			-0.010*** (-3.5)
S 점수			-0.004* (-1.9)		-0.006* (-1.9)
G 점수				0.004** (2.0)	0.010*** (3.9)
부실 변수	0.059 (0.3)	0.089 (0.4)	0.056 (0.2)	0.088 (0.4)	0.155 (0.7)
Tobin's Q	0.253*** (5.6)	0.245*** (5.4)	0.249*** (5.5)	0.247*** (5.4)	0.222*** (4.8)
ROA	0.445 (0.8)	0.509 (0.9)	0.449 (0.8)	0.451 (0.8)	0.543 (1.0)
총자산	-0.251*** (-3.5)	-0.264*** (-3.7)	-0.254*** (-3.6)	-0.253*** (-3.6)	-0.272*** (-3.8)
고정자산비율	0.003 (0.2)	0.005 (0.3)	0.004 (0.2)	0.003 (0.2)	0.006 (0.4)
레버리지	-6.259*** (-21.9)	-6.254*** (-22.0)	-6.247*** (-21.9)	-6.265*** (-22.0)	-6.249*** (-22.0)
Z-점수	0.007* (1.9)	0.007* (1.9)	0.007* (1.9)	0.007* (1.8)	0.007* (1.8)
산업레버리지	22.671*** (7.5)	18.604*** (7.3)	20.525*** (7.6)	27.257*** (8.9)	24.839*** (8.0)
상수	-6.141*** (-3.6)	-4.012*** (-2.8)	-4.970*** (-3.2)	-8.677*** (-5.0)	-7.489*** (-4.3)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	5915	5915	5915	5915	5915
adj. R-sq	0.737	0.737	0.737	0.737	0.738

〈표 12〉에서 가장 뚜렷하게 확인할 수 있는 부분은 기업의 ESG 정보 중 지배구조(G) 정보가 기업의 부도거리를 증가시키는 것에 있어서 통계적으로 유의한 효과를 가지고 있다는 점이다. 개별 ESG 점수를 모두 포함한 회귀 분석에서 G 점수의 계수는 0.01로서 양의 방향으로 통계적 유의성을 가진 것으로 나와 지배구조 개선이 기업의 부도거리를 늘려 부실 위험을 줄이는 역할을 할 수 있는 것을 시사한다.

이러한 지배구조 개선의 역할을 기존 문헌에서도 많이 연구된 것이라고 할 수 있다. 국내 기업에서 지배구조 개선은 코리아 디스카운트를 줄일수 있는 주요 요인으로 알려져 있으며, 이러한 코리아 디스카운트가 줄어들에 따라 주식 가치가 올라가고, 투자 유치가 더 용이해져 자본 조달 비용이 감소할 수 있다. 이에 따라 기업의 부실확률이 낮아 질수 있으며 부도 확률이 증가할 수 있다.

한편 환경 영역은 오히려 음의 성과를 나타내고 있다. 이와 같이 환경 영역의 성과가 부도확률에 음의 영향을 미치는 경우는 크게 경제적 논의를 생각할 수 있다. 첫 번째는 Aupperle et al.(1985)에서 일반적인 사회공헌활동에서 밝히듯 환경 관련 활동을 기업의 비용으로 인식하는 경우이다. 즉 환경 성과가 높은 기업에서 비용이 늘어나게 되며, 이에 따라 기업의 현금흐름을 위축시키고 이에 따라 부실 위험을 증가시킬 수 있다는 논의이다.

반면에 표본 기간내 ESG 경영활동이 활성화 되지 않아 재무적으로 우량한 기업들이 환경 경영에 적극적으로 참여하지 않고 이에 따라 부도거리와 환경경영의 성과가 음의 관계를 보일 수도 있다. 예를 들어, 우리나라의 경우 탄소배출권 거래제가 도입되었지만 탄소배출권 가격이 매우 낮아 재무적인 실효성이 없는 상황이었다. 코로나19 기간이 지나고 본격적으로 탄소 감축에 대한 논의가 진행되고 이에 따라 환경리스크 및 그 대응에 대한 투자자 인식이 변화하고 있는 상황이라고 할 수 있다.

한편 사회 성과 역시 통계적으로 유의성은 약하나 기업의 부도거리와 음의 관계를 보이고 있다. ESG 경영이 본격화되기 이전 시점에 사회 영역활동 역시 기업 경영 측면에 있어서 비용 측면으로서 인식될 가능성이 높다고 할 수 있다.

〈표 13〉 ESG 정보와 부도거리: 환경 성과 0 이상

독립변수	부도거리				
ESG 점수	0.004				
	(1.3)				
E 점수		-0.003			-0.004
		(-0.8)			(-0.9)
S 점수			0.005		0.005
			(1.0)		(1.1)
G 점수				0.012**	0.012*
				(2.0)	(2.0)
부실 변수	0.401	0.404	0.382	0.427	0.440
	(1.1)	(1.1)	(1.0)	(1.1)	(1.2)
Tobin's Q	0.172***	0.176***	0.177***	0.167***	0.170***
	(3.2)	(3.3)	(3.3)	(3.1)	(3.1)
ROA	1.635*	1.713**	1.648*	1.649*	1.652*
	(1.9)	(2.0)	(1.9)	(1.9)	(1.9)
총자산	-0.426***	-0.428***	-0.422***	-0.434***	-0.436***
	(-4.0)	(-4.0)	(-4.0)	(-4.1)	(-4.1)
고정자산비율	0.013	0.013	0.014	0.015	0.017
	(0.3)	(0.3)	(0.3)	(0.3)	(0.4)
레버리지	-6.313***	-6.309***	-6.327***	-6.288***	-6.303***
	(-13.9)	(-13.9)	(-14.0)	(-13.9)	(-13.9)
Z-점수	0.016**	0.016**	0.016**	0.015**	0.015**
	(2.3)	(2.3)	(2.3)	(2.2)	(2.2)
산업레버리지	80.823***	76.690***	77.642***	78.935***	78.594***
	(12.8)	(13.4)	(13.6)	(13.8)	(13.6)
상수	-35.307***	-32.986***	-33.626***	-34.853***	-34.797***
	(-10.5)	(-11.0)	(-11.3)	(-11.4)	(-11.2)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	3656	3656	3656	3656	3656
adj. R-sq	0.758	0.758	0.758	0.758	0.758

한편 이러한 환경 성과와 기업 부도거리 간의 관계를 면밀히 분석하고자 〈표 10〉은 환경성과가 0 이상인 기업들에 대해서 분석하였다. 실제 표본의 상당수 기업에 대해 환경성과가 0으로 보고가 되어 표본의 숫자가 상당 부분 감소하였다.

〈표 13〉의 경우 환경성과에 대한 부정적인 효과가 사라진 것으로 확인되었다. 개별 ESG 점수를 모두 포함한 회귀 분석에서 지배구조(G) 점수의 계수는 0.012로서 여전히 양의 방향으로 통계적 유의성을 가진 것으로 나와 지배구조 개선이 기업의 부도거리를 늘려 부실 위험을 줄이는 역할을 하는 것이 확인되고 있다. 반면 환경 성과의 계수는 -0.004부터 -0.003으로 그 절대적인 효과가 감소하여 통계적 유의성이 사라진 것으로 나타나고 있다.

〈표 14〉 ESG 정보와 부도거리: 부도거리 중위수 이상

독립변수	부도거리				
ESG 점수	-0.000 (-0.1)				
E 점수		-0.012*** (-3.4)			-0.013*** (-3.0)
S 점수			-0.004 (-1.1)		-0.004 (-0.8)
G 점수				0.004 (1.5)	0.010** (2.5)
부실 변수	0.168 (0.4)	0.242 (0.6)	0.170 (0.4)	0.206 (0.5)	0.338 (0.8)
Tobin's Q	0.196*** (3.2)	0.191*** (3.1)	0.192*** (3.1)	0.189*** (3.1)	0.173*** (2.8)
ROA	0.812 (0.9)	0.928 (1.0)	0.823 (0.9)	0.822 (0.9)	0.974 (1.0)
총자산	-0.394*** (-3.0)	-0.406*** (-3.1)	-0.394*** (-3.0)	-0.396*** (-3.0)	-0.411*** (-3.1)
고정자산비율	0.013 (0.6)	0.014 (0.6)	0.014 (0.6)	0.012 (0.5)	0.013 (0.6)
레버리지	-8.557*** (-16.1)	-8.602*** (-16.2)	-8.550*** (-16.1)	-8.585*** (-16.2)	-8.663*** (-16.4)
Z-점수	0.007 (1.3)	0.007 (1.3)	0.007 (1.4)	0.007 (1.3)	0.006 (1.2)
산업레버리지	33.850*** (6.5)	28.383*** (6.4)	31.356*** (6.6)	38.722*** (7.4)	35.748*** (6.8)
상수	-11.648*** (-4.1)	-8.778*** (-3.6)	-10.291*** (-4.0)	-14.326*** (-5.0)	-12.853*** (-4.5)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	3716	3716	3716	3716	3716
adj. R-sq	0.638	0.639	0.638	0.638	0.640

이러한 결과는 환경성과와 기업 부도거리 간의 경제적 논의에 있어서 두 번째 시나리오를 뒷받침한다고 할 수 있다. 즉 재무적으로 건전한 많은 기업들이 기간 내 환경경영에 적극적으로 참여하지 않아 환경 성과가 좋지 않았고 이에 따라 부도거리와 환경성과의 관계가 음의 관계가 나타날 수 있는 것이다. 추후 환경 영역에 대한 투자자 인식이 제고된 상태에서 이러한 분석을 재수행해 볼 필요가 있을 것으로 사료된다.

〈표 14〉에서는 ESG 성과와 기업의 부도거리와의 관계를 부도거리가 중위수 이상인 기업들에 대해서 분류하였다. 부도거리 측정이 전체 표본을 통해서 이루어지고, ESG 정보가 있는 기업들이 비교적 우량한 기업들이므로 따라 표본이 절반으로 감소하지는 않았다.

이러한 우량 기업에서 분석 결과는 전체 결과의 강건성을 뒷받침하고 있다고 사료된다. 즉 지배구조 개선의 부도거리 측면에 있어서 긍정적인 효과 환경성과의 부정적인 성과가 동시에 확인되고 있다. 특히 E 점수, S 점수, G 점수를 모두 사용한 분석에 있어서 전체 표본과의 유사성이 두드러진다고 할 수 있다.

〈표 15〉에서는 ESG 성과와 기업의 부도거리와의 관계를 부도거리가 중위수 이하인 기업들에 대해서 분류하였다. 이를 통해 ESG 정보와 부도거리와의 관계에 강건성을 찾아보고자 시도하였다.

〈표 11〉과 마찬가지로 〈표 12〉에서의 결과 역시 ESG 정보와 기업의 부도거리 간에 강건한 관계를 확인하였다. E, S, G 점수가 각각 반영된 모형에서 여전히 환경 영역 성과는 부도거리 차원에서 부정적인 영향, 지배구조 성과는 긍정적인 영향을 주고 있어 모형 추정치의 강건성을 보여주고 있다고 할 수 있다.

한편 국내시장에서 특수한 지배구조를 가진 대기업 기업 집단인 재벌의 경우 ESG 성과가 기업 가치 등에 미치는 영향이 상이하다는 연구들이 다수 존재한다(Yoon et al., 2018; 이정환 외, 2022). 많은 재벌 기업들의 경우 기업 지분구조의 특성상 소유와 경영의 분리라는 기업 경영의 대원칙을 달성하기가 어렵고 이에 따라 지배구조 개선에 제약이 있는 것이 사실이라고 할 수 있다.

〈표 15〉 ESG 정보와 부도거리: 부도거리 중위수 이하

독립변수	부도거리				
ESG 점수	-0.001				
	(-1.3)				
E 점수		-0.005***			-0.005***
		(-4.5)			(-4.2)
S 점수			-0.002*		-0.003*
			(-1.7)		(-1.9)
G 점수				0.002**	0.005***
				(2.0)	(4.3)
부실 변수	-0.274***	-0.270***	-0.273***	-0.263***	-0.253***
	(-3.5)	(-3.5)	(-3.5)	(-3.4)	(-3.3)
Tobin's Q	0.202***	0.182***	0.197***	0.198***	0.154***
	(4.1)	(3.7)	(4.0)	(4.1)	(3.1)
ROA	0.471**	0.477**	0.461**	0.467**	0.495**
	(2.1)	(2.2)	(2.1)	(2.1)	(2.3)
총자산	0.011	0.004	0.010	0.013	0.001
	(0.5)	(0.1)	(0.4)	(0.5)	(0.0)
고정자산비율	0.011	0.016	0.011	0.011	0.019
	(0.9)	(1.3)	(0.9)	(1.0)	(1.6)
레버리지	-1.638***	-1.626***	-1.635***	-1.647***	-1.616***
	(-14.3)	(-14.3)	(-14.3)	(-14.4)	(-14.2)
Z-점수	-0.001	-0.001	-0.001	-0.001	-0.000
	(-0.4)	(-0.3)	(-0.4)	(-0.3)	(-0.1)
산업레버리지	6.289***	5.212***	6.308***	8.951***	8.201***
	(5.5)	(5.4)	(6.2)	(7.5)	(6.9)
상수	-0.998	-0.415	-1.005*	-2.446***	-2.034***
	(-1.6)	(-0.8)	(-1.8)	(-3.7)	(-3.1)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	2199	2199	2199	2199	2199
adj. R-sq	0.452	0.457	0.452	0.452	0.463

〈표 16〉 ESG 정보와 부도거리: 재벌 기업

독립변수	부도거리				
ESG 점수	-0.001				
	(-0.3)				
E 점수		-0.007**			-0.010***
		(-2.6)			(-3.0)
S 점수			-0.000		0.004
			(-0.1)		(0.9)
G 점수				0.005	0.005
				(1.3)	(1.2)
부실 변수	0.556	0.637	0.559	0.601	0.736*
	(1.3)	(1.5)	(1.3)	(1.4)	(1.7)
Tobin's Q	0.730***	0.704***	0.731***	0.729***	0.703***
	(6.8)	(6.6)	(6.8)	(6.8)	(6.5)
ROA	1.533*	1.628*	1.534*	1.575*	1.709**
	(1.8)	(2.0)	(1.8)	(1.9)	(2.0)
총자산	-0.114*	-0.123*	-0.114*	-0.116*	-0.128*
	(-1.7)	(-1.8)	(-1.7)	(-1.7)	(-1.9)
고정자산비율	-0.028	-0.018	-0.028	-0.026	-0.013
	(-0.6)	(-0.4)	(-0.6)	(-0.6)	(-0.3)
레버리지	-7.234***	-7.268***	-7.236***	-7.221***	-7.270***
	(-13.6)	(-13.7)	(-13.6)	(-13.6)	(-13.7)
Z-점수	0.009	0.011	0.009	0.009	0.011
	(1.0)	(1.2)	(1.0)	(1.0)	(1.2)
산업레버리지	36.733***	31.286***	37.479***	42.613***	38.320***
	(7.0)	(7.1)	(7.7)	(8.1)	(6.9)
상수	-12.925***	-9.974***	-13.333***	-16.180***	-13.873***
	(-4.5)	(-4.1)	(-5.0)	(-5.6)	(-4.6)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	1393	1393	1393	1393	1393
adj. R-sq	0.814	0.815	0.814	0.814	0.816

〈표 16〉에서 재벌 기업 내의 ESG 성과와 기업의 부도거리와의 관계를 분석해 본 결과는 전체 표본 분석이나 부도거리 기준 표본 분석이 상이한

양상을 보이고 있다. 가장 주목할 점은 지배구조의 개선이 부도 확률을 줄이는 것에 미치는 영향에 대한 통계적인 유의성이 사라졌다는 것이다 실제 E,S,G 점수가 각각 반영된 모형에서 지배구조 점수의 계수는 0.005로서 여전히 양의 계수를 지니기는 하지만 통계적인 유의성이 사라져 버렸다. 반면 환경 영역의 부도거리 차원에서 부정적인 성과는 강건하게 발견되고 있다.

〈표 17〉 ESG 정보와 부도거리: 비재벌 기업

독립변수	부도거리				
ESG 점수	0.004				
	(1.6)				
E 점수		-0.004			-0.006
		(-1.0)			(-1.3)
S 점수			0.001		-0.003
			(0.2)		(-0.6)
G 점수				0.003	0.006*
				(1.3)	(1.7)
부실 변수	0.015	0.005	0.005	0.023	0.035
	(0.1)	(0.0)	(0.0)	(0.1)	(0.1)
Tobin's Q	0.116**	0.122**	0.121**	0.115**	0.112**
	(2.2)	(2.3)	(2.3)	(2.2)	(2.1)
ROA	-0.094	-0.043	-0.057	-0.065	-0.051
	(-0.1)	(-0.1)	(-0.1)	(-0.1)	(-0.1)
총자산	-0.487***	-0.491***	-0.488***	-0.490***	-0.496***
	(-4.1)	(-4.2)	(-4.1)	(-4.2)	(-4.2)
고정자산비율	0.006	0.007	0.007	0.006	0.007
	(0.3)	(0.4)	(0.4)	(0.4)	(0.4)
레버리지	-6.048***	-6.061***	-6.057***	-6.058***	-6.063***
	(-17.7)	(-17.7)	(-17.7)	(-17.7)	(-17.7)
Z-점수	0.007	0.007	0.007	0.007	0.007
	(1.6)	(1.6)	(1.6)	(1.6)	(1.5)
산업레버리지	22.543***	17.239***	18.938***	22.070***	21.352***
	(6.0)	(5.5)	(5.7)	(5.7)	(5.5)
상수	-6.115***	-3.208*	-4.118**	-5.856***	-5.505**
	(-2.9)	(-1.9)	(-2.2)	(-2.7)	(-2.5)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	4522	4522	4522	4522	4522
adj. R-sq	0.726	0.725	0.725	0.725	0.726

이러한 결과는 재벌이 가진 지배구조적 특성과 밀접한 관련성이 있을 수 있다. 우선 이미 언급한 바와 같이 재벌의 지분-경영구조 특성상 지배구조 개선이 가지는 본질적인 한계에 따라 추가적인 개선의 가능성이 제약될 수 있다. 더욱이 국내 ESG 등급업체에서 측정하는 지배구조 관련 정보 역시 이사회 조직, 이사회 개최 건수, 감사 위원회 여부, 지속가능경영 체계 구축 등 형식적이고 수량적인 요소가 대부분이다. 이러한 형식적인 요소는 국내 대기업들이 비교적 용이하게 대응할 수 있는 부분이므로 재벌기업집단 내에서 ESG 평가 정보가 가지는 부도거리에 대한 영향은 미흡할 수 있을 가능성이 있다.

한편 비재벌 기업 내의 ESG 성과와 기업의 부도거리와의 관계를 분석해 본 <표 17>의 결과는 지배구조 영역에서 우수한 성과가 부도거리를 증가시키는 효과를 뒷받침한다고 할 수 있다. 실제 E, S, G 점수가 각각 반영된 모형에서 지배구조 점수의 계수는 0.006로서 통계적으로 유의한 양의 값을 지니고 있었다.

이에 따라 전체 표본에서 지배구조 개선이 부도거리에 미치는 효과는 많은 부분 비재벌 기업 집단군에서 발생한 효과라고 생각될 수 있다. 즉 비재벌 기업에서 지배구조 개선 가능성이 부도거리 개선을 이끌고 이러한 효과가 전체 표본의 결과로 나타나는 것으로 사료된다.

애널리스트 커버리지 분석

이제 부도거리와 애널리스트 커버리지와의 관계를 분석해 보고자 한다. ESG 정보 분석과 마찬가지로 기업별 고정효과 및 시간 고정효과까지 고려한 패널 회귀 모형을 통해 부도거리와 애널리스트 커버리지와의 관계를 추정하였다.

〈표 18〉 애널리스트 커버리지와 부도거리

독립변수	전체	점수L	점수H	재벌	비재벌
애널리스트	-0.043	0.156	-0.343	0.387***	-0.197
	(-0.5)	(1.4)	(-0.7)	(2.9)	(-1.6)
부실 변수	0.088	0.327	0.556	0.704	0.222
	(0.3)	(1.0)	(1.2)	(1.6)	(0.6)
Tobin's Q	0.635***	0.503***	0.676***	0.967***	0.596***
	(10.8)	(7.9)	(5.6)	(9.8)	(6.0)
ROA	1.080*	2.251***	0.516	1.021	-0.235
	(1.7)	(3.2)	(0.4)	(1.3)	(-0.2)
총자산	-0.065	-0.080	-0.066	0.013	-0.190
	(-1.0)	(-1.2)	(-0.5)	(0.2)	(-1.5)
고정자산비율	-0.069**	-0.075**	-0.105*	0.003	-0.047
	(-2.4)	(-2.4)	(-1.9)	(0.0)	(-1.3)
레버리지	-7.598***	-6.729***	-8.192***	-7.218***	-8.491***
	(-24.8)	(-17.8)	(-14.4)	(-17.2)	(-17.9)
Z-점수	0.000	0.003	-0.006	-0.001	0.006
	(0.0)	(0.6)	(-0.9)	(-0.2)	(1.1)
산업레버리지	-3.107***	-3.159***	-3.332**	2.026	-4.109***
	(-4.2)	(-3.7)	(-2.0)	(1.4)	(-3.7)
상수	5.738***	4.946***	7.170***	2.599**	7.571***
	(7.4)	(5.6)	(3.1)	(2.4)	(7.3)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	3596	1754	1842	1589	2007
adj. R-sq	0.785	0.838	0.760	0.829	0.768

〈표 18〉에서는 애널리스트 커버리지와 부도거리 분석 결과를 보고하였다. 전체 표본에 대한 결과, 애널리스트 커버리지 점수가 커버리지 점수 중위수 이하인 기업에 대한 분석결과(점수 L), 커버리지 점수 중위수 이상인 기업에 대한 분석결과(점수 H) 및 재벌 및 비재벌 기업에 대해 모형 분석을 수행하였다. 애널리스트들이 분석하는 기업들이 한정적임에 따라 표본수 역시 제약되었다고 할 수 있다.

재벌 기업을 제외하고는 애널리스트 커버리지는 부도거리에 있어서 통계적으로 유의한 영향을 미치지 않는 것으로 나타났다. 오히려 재벌과 점수 L을 제외한 경우에 대해서 통계적으로 유의하지 않고, 음의 결과 즉 커버리지가

높을수록 부도거리가 줄어 부도 확률이 높아지는 결과를 나타내고 있다.

유일한 예외는 재벌기업으로서 재벌기업의 애널리스트 커버리지는 통계적으로 유의하게 부도거리를 늘리는 효과를 나타내고 있다. 주식 시장에서 큰 비중을 차지하는 재벌집단군에 대해 보다 엄밀한 기업분석을 수행함으로써 부도거리에 대한 실질적인 정보를 제공할 수도 있음을 시사하고 있다.

〈표 19〉 애널리스트 커버리지와 부도거리- ESG 정보 포함

독립변수	전체	점수L	점수H	재벌	비재벌
애널리스트	-0.238 (-1.5)	0.137 (0.5)	-0.732 (-1.2)	0.202 (0.9)	-0.381 (-1.6)
E 점수	-0.008** (-2.4)	-0.008* (-1.7)	-0.009* (-1.8)	-0.012*** (-3.1)	0.002 (0.3)
S 점수	0.000 (0.1)	0.003 (0.4)	0.003 (0.5)	0.007 (1.3)	0.002 (0.2)
G 점수	0.013*** (3.0)	0.033*** (4.0)	0.003 (0.6)	0.011* (1.7)	0.005 (0.7)
부실 변수	-0.470 (-0.8)	0.767 (1.0)	-0.764 (-0.9)	0.510 (0.6)	-0.954 (-1.2)
Tobin's Q	0.654*** (8.2)	0.585*** (6.1)	0.636*** (4.4)	0.738*** (5.8)	0.564*** (4.4)
ROA	3.610*** (3.5)	3.990*** (2.6)	2.301 (1.5)	4.065*** (3.0)	2.473 (1.5)
총자산	-0.158* (-1.9)	-0.339*** (-3.7)	-0.027 (-0.1)	-0.201** (-2.4)	-0.056 (-0.3)
고정자산비율	-0.022 (-0.3)	0.069 (0.7)	-0.099 (-1.1)	0.154 (1.5)	-0.164* (-1.7)
레버리지	-8.139*** (-15.0)	-7.456*** (-9.8)	-8.709*** (-10.4)	-8.109*** (-11.4)	-8.400*** (-9.4)
Z-점수	0.009 (0.8)	-0.006 (-0.4)	0.025 (1.4)	0.006 (0.4)	0.047* (1.9)
산업레버리지	42.895*** (7.4)	64.712*** (5.9)	35.868*** (4.6)	43.201*** (5.1)	41.338*** (4.6)
상수	-15.517*** (-4.5)	-31.276*** (-5.2)	-9.368** (-2.0)	-17.323*** (-3.6)	-13.437*** (-2.7)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	2105	801	1304	1004	1101
adj. R-sq	0.820	0.877	0.791	0.844	0.796

ESG 정보와 부도거리와의 관계를 추정한 이전 결과들을 바탕으로 <표 19>에서는 기존 기업 특성 변수에 ESG 정보를 추가하여 기업의 부도거리와 애널리스트 커버리지와의 관계를 분석하였다.

<표 15>의 애널리스트 커버리지 분석과 달리 <표 16>의 분석 결과는 재별기업 집단 내에서도 애널리스트 커버리지 정보가 부도거리에 미치는 영향이 통계적으로 유의하지 않음을 밝히고 있다. 전체 표본 및 모든 부분 표본에서 애널리스트 커버리지는 부도거리와 통계적으로 유의한 관계를 보이지 못하고 있으며, 여전히 재별 기업을 제외하면 (통계적으로 유의성은 없지만) 오히려 부도거리와 음의 관계를 보이고 있는 것으로 확인되어 재무 이론들과 부합하지 않는다고 할 수 있다.

이와 같이 통계적으로 유의하지 않는 결과는 비교적 시장 전망이 좋은 한정적인 기업에 대해서만 분석하는 애널리스트 커버리지의 특징에 기인한 것으로 생각될 수 있다. 즉 우량한 기업 위주의 단기적인 성과 변동 분석과 시장 관련 분석이 집중됨으로서, 기업의 하향 리스크를 측정하는 부도거리와의 관계성이 명확하지 않을 가능성이 있다.

탄소 배출량 분석

마지막으로 부도거리와 탄소배출과 커버리지와의 관계를 분석해 보고자 한다. ESG 정보 분석이나 애널리스트 커버리지 분석과 마찬가지로 기업별 고정효과 및 시간 고정효과까지 고려한 패널 회귀 모형을 통해 탄소배출량과 부도거리와의 관계를 분석하고자 한다. 탄소배출량은 당해 회계연도 매출액으로 나누어 표준화하였다.

한편 본 연구의 탄소 배출량은 자발적 탄소배출공시 기준으로 측정한 결과임에 따라 기업별 차이가 발생할 수 있다. 이에 따라 표본기간(2013~2017년)에 대해 KOSPI 시장에 상장한 상장사중 본 연구에 기준에 맞는 기업들중 탄소 배출 정보가 있는 기업과 없는 기업의 부도거리, 토빈의 Q, ROA, 로그 총자산, 고정자산 비율, 부채비율, Z-점수의 평균과 표준편차를 계산해 보았다.

〈표 20〉 탄소배출 기업과 그렇지 않은 상장기업의 차이

변수명	탄소배출 정보가 있는 기업			탄소배출정보가 없는 기업		
	관측치수	평균	표준편차	관측치수	평균	표준편차
부도거리	775	4.605	3.198	2638	3.893	3.665
Tobin's Q	675	1.439	1.001	2365	1.093	0.737
ROA	675	0.097	0.068	2365	0.053	0.075
총자산	675	0.093	0.248	2372	0.053	0.364
고정자산비율	649	0.502	1.760	2307	0.889	2.526
부채비율	767	0.489	0.185	2625	0.469	0.224
Z-점수	595	6.293	8.131	2252	5.360	12.492

〈표 20〉의 결과 예측한 바와 같이 탄소 배출 기업의 ROA 및 총자산의 평균이 탄소배출정보가 없는 기업에 비해 우수한 것으로 확인되고 있다. 이에 따라 부도 거리 역시 탄소거리가 있는 기업이 탄소기업이 없는 기업보다 우수한 것으로 나타나고 있으며, 기업의 시장가치를 측정하는 토빈의 Q 역시 탄소배출하는 기업에서 우수한 성과를 보여, 비교적 규모가 크고 수익성이 높은 기업에서 탄소배출 정보를 많이 제공하고 있는 것을 확인할 수 있었다.

한편 〈표 20〉에서는 보고하지 않았지만 본 연구가 독립변수로서 사용하는 탄소배출량 측도인 매출액 대비 탄소 배출의 비율, 즉 탄소집중도(carbon intensity)는 기업 내 변동이 유의한 것으로 확인된다. 실제 탄소배출 기업 평균의 평균 탄소집중도는 0.0058이지만, 2013~2017년 탄소배출 기업의 기업별 탄소배출의 표준편차의 평균값은 0.0036으로 상당히 유의한 수준이었다. 이는 배출권 거래제등의 논의에서 많이 분석된 사항으로서 경기나 업황 변동으로 원자재 사용 및 전기 사용량이 크게 변하면서 기업별 탄소 배출량이 상당히 많이 변한다는 논의와 일관된다고 할 수 있다.

〈표 21〉에서는 탄소 배출량과 부도거리 분석 결과를 보고하였다. 전체 표본에 대한 결과, 부도거리 점수가 부도거리 중위수 이하인 기업에 대한 분석결과(DD_L), 부도거리 중위수 이상인 기업에 대한 분석 결과(DD_H) 및 재별 및 비재별 기업에 대해 모형 분석을 수행하였다. 탄소배출권 데이터가 2013~2017년 기간에 수집되었고, CDP에 정보제공한 기업들 중 일부만

실제 공개가 되어서 표본 수가 감소되었다.⁶⁾

〈표 17〉의 결과는 탄소배출량과 부도거리간의 유의한 관계가 없음을 시사하고 있다. 모든 표본에 있어서 탄소배출량과 부도거리는 통계적으로 유의한 관계가 나타나고 있지 않으며 그 부호 역시 전체 표본 및 세부 그룹별로 상이한 양상을 보이고 있다.

이와 같은 〈표 17〉의 결과는 탄소 배출 리스크가 잘 분석되지 않았던

〈표 21〉 탄소배출 정보와 부도거리

독립변수	전체	DD_L	DD_H	재벌	비재벌
탄소 배출	0.005	0.013	-0.013	-0.004	-0.028
	(0.1)	(0.9)	(-0.1)	(-0.1)	(-0.3)
부실 변수	2.348*	0.754	1.853	1.564	6.625**
	(1.7)	(1.5)	(0.8)	(1.2)	(2.1)
Tobin's Q	0.560***	2.824***	0.498***	0.802***	0.410
	(3.8)	(3.7)	(3.0)	(3.6)	(1.6)
ROA	3.598	2.118*	6.419*	5.057**	4.479
	(1.5)	(1.8)	(1.9)	(2.3)	(0.8)
총자산	-0.248	0.452	-0.184	-0.206	-0.640
	(-0.8)	(1.1)	(-0.4)	(-0.8)	(-0.8)
고정자산비율	-0.002	-0.023	0.296	0.023	-0.919
	(-0.0)	(-0.4)	(0.5)	(0.3)	(-0.7)
레버리지	-7.950***	-3.291***	-8.746***	-6.096***	-11.106***
	(-5.3)	(-2.8)	(-4.8)	(-3.9)	(-3.4)
Z-점수	-0.010	0.036	-0.024	0.003	-0.172
	(-0.2)	(0.8)	(-0.5)	(0.1)	(-1.5)
산업레버리지	-1.094	2.113	-2.890	6.022**	-19.836***
	(-0.5)	(1.3)	(-1.0)	(2.6)	(-3.3)
상수	6.477***	-0.316	7.643***	3.278**	17.609***
	(3.6)	(-0.2)	(3.7)	(2.1)	(4.7)
기업고정효과	Y	Y	Y	Y	Y
시간고정효과	Y	Y	Y	Y	Y
관측치	592	122	470	378	214
adj. R-sq	0.868	0.750	0.821	0.906	0.800

6 실제 보다 광범위한 데이터 기간과 분석범위를 가진 Trucost 탄소데이터를 한국 기업에 적용해도 동일한 결론을 얻을 수 있다.

표본 기간의 특성이 반영된 것으로 사료된다. 실제 아직까지 국내 탄소배출권 거래 가격은 낮은 수준으로서 탄소 발생 감축을 위한 기업들에 부담이 아직 심하지 않은 상황이라고 할 수 있다. 국가 차원의 탄소 리스크 관리 역시 2021년 파리협약 6조가 공표되면서 본격화 하는 시점인 관계로 탄소 배출권 혹은 탄소 리스크와 기업의 부실과의 관계는 향후 보다 엄밀히 분석해야 될 필요성이 있는 것으로 사료된다.

V. 결론

본 연구는 대안 신용평가 모형을 구축하기 위하여 기존 신용평가사 모형 로직을 학습하여 비자발적 상장 폐지 기업에 대해 확장 분석하고, 탄소배출량, ESG 성과, 애널리스트 커버리지 등의 대안 정보의 신용평가 모형에 있어서 활용 가능성에 대해서 분석하였다.

본 연구의 분석 결과는 다음과 같다. 본 연구는 우선 랜덤포레스트 및 그래디언트부스티드디시전트리 모형을 활용하여 기업의 재무정보 및 거시경제 정보를 바탕으로 기존 신용평가사의 평가로직을 머신러닝 모형으로 재현해 보았다. 머신러닝 모형으로 신용평가사가 제공한 투자 적격/비적격 등급 신용 등급을 예측하고 전통적인 로짓 모형과 비교해 보는 분석을 수행하였다. 그 결과 머신러닝 모형은 95% 가량의 높은 정확도를 보여 신용평가사의 신용평가를 기계학습을 통해 신용평가 등급이 없는 다른 기업에 대해 확장할 수 있는 가능성을 확인하였다.

한편 이렇게 머신러닝을 통해 학습한 현재 국내 신용 평가사의 등급 산정 로직을 바탕으로 비자발적 상장폐지 기업을 분석해 본 결과 설명력이 높은 것으로 나타났다. 실제로 이들 기업은 채권 발행이 어려우므로 신용 등급이 부여되지는 않았지만, 이들 기업의 재무제표를 기반으로 상장 폐지 당시의 투자 비적격 등급 이하로의 예측 확률이 평균 88%, 중위값 95% 이상의 높은 예측력을 보였으며, 시계열적으로도 이러한 부실 예측 상장폐지 직전까지 지속적으로 늘어나는 것을 확인하여 경제적 설명에 부합하였다. 재무지표만을 기준으로 평가하는 기존 신용 모형의 높은 예측 성과는 최종적인 기업의 부실은 기업 성과와 유동성 영역의 재무적인 영역임을 확인해 주고 있다.

이와 같은 부도확률을 통해 기존 신용평가 영역을 조절한 후 부도거리와 비재무적 정보와의 관련성을 분석해본 결과, 본 연구는 ESG 지표가 대안신용평가 모형에 활용할 수 있음을 확인하였다. 특히 기업지배구조 관련 지표가 비재벌기업집단군을 중심으로 비교적 강건하게 확인되어 지배구조 개선이 부도확률을 줄일 수 있는 긍정적인 효과를 확인하였다. 반면 환경 영역의

성과 관련해서는 오히려 많은 경우 부정적인 효과를 확인하였고, 환경 위험성에 관한 투자자 인식이 높아진 후에 재분석이 필요하다는 것을 강조하였다. 반면 애널리스트 커버리지 정보, 그리고 탄소배출량과 같은 대안 정보는 기업의 부도거리에 대한 설명력이 낮은 것으로 나타났다. 이는 성장성 등이 좋은 특정기업군에 집중하는 애널리스트 커버리지의 특성, 낮은 탄소배출권 가격 등으로 인한 탄소 위험성에 대한 인식 부족 등으로 설명 가능할 것으로 사료된다.

본 연구의 주요 공헌점은 다음과 같다. 첫째, 본 연구는 머신러닝 모형을 도입하여 기존의 재무기반 신용 평가 모형을 보다 광범위하게 적용할 수 있는 방법론을 제시하여, 주로 채권 발행기업 위주로 한정적으로 제공되던 신용평가 관련 분석을 확장할 수 있는 프레임워크를 제시하였다. 이러한 방법론에 따라 본 연구는 채권 발행의 어려움에 따라 신용 평가 등급이 없어 기존에 분석되지 않던 비자발적 상장 폐지라는 부도에 준하는 사건을 신용 등급 관련 연구와 연결시켰다는 공헌점이 있다. 한편 본 연구는 ESG 정보가 추후 신용 등급 평가에 반영할 수 있는 주요한 정보가 될 수 있음을 확인하였으며, 탄소나 환경과 같은 대안 정보들을 신용평가 모형에 활용할 경우 추가적인 분석이 필요함을 밝혔다.

참고문헌

- 고대영·안미강 (2017), “환경정보공시가 외국인지분율에 미치는 영향”, 산업경제연구, 30(4), pp.1275-1296.
- 권황현 (2020), “머신러닝과 금융: 머신러닝 기반 신용평가모형”, 산은조사월보, 711, pp.3-16.
- 김광민·이현상 (2021), “ESG 등급이 기업가치와 부채비용, 신용등급에 미치는 영향”, 아태경상저널, 13(3), pp.94-121.
- 박도준·박혜진·이혜진 (2022), “기업의 ESG 활동이 신용위험 및 평가에 미치는 영향”, 2022년 한국재무학회 추계학술대회 발표 논문, pp.1-30.
- 박정환·노정희 (2017), “기업의 온실가스 배출량이 기업가치에 미치는 영향”, 산업경제연구, 30(5) pp.1643-1663.
- 박주완·송창길·배진성 (2017), “기계학습 기법을 이용한 소상공인 신용평가모형 구축에 관한 연구”, 한국비즈니스리뷰, 10(3), pp.1-16.
- 송민찬·류두진 (2021), “기계학습 기반 기업신용정보 분석을 통한 채무불이행 예측”, 재무연구 34(4), pp.199-234.
- 송성환·한정석·최수정·박성민 (2017), “머신 러닝 기반 소셜 빅데이터 분석을 이용한 금융자산 트레이딩 모델의 성능 향상에 관한 연구”, Entrue Journal of Information Technology, 16(1), pp.51-62.
- 서문석·김동호 (2019), “빅데이터 기반의 핀테크서비스 모델의 변화 방향에 관한 연구”, e-비즈니스연구, 20(2), pp.195-213.
- 서민교 (2013), “국내 금융기관의 빅 데이터(Big Data)활용 사례에 관한 연구”, 전자무역연구, 11(4), pp.115-134.
- 오상희 (2021), “신용등급 및 ESG 등급이 기업가치에 미치는 영향에 관한 연구”, 세무회계연구, 69, pp.125-144.
- 윤보현·이정환·하 준·손삼호 (2016), “기업재무 데이터특성을 고려한 자본구조조정속도 추정에 관한 연구”, 지역산업연구, 39(2), pp.55-84.

- 이승훈·김수현 (2022), “국내 애널리스트의 커버리지와 상장사 R&D 활동의 관계 검증”, *재무관리연구*, 39(1), pp.1-22.
- 이재웅·김영식·권오병 (2016), “비정형 데이터 분석을 통한 금융소비자 유형화 및 그에 따른 금융상품 추천 방법”, *한국IT서비스학회지*, 15(4), pp.1-24.
- 이재홍·오명전 (2013), “비정상투자가 신용등급에 미치는 영향”, *회계정보연구*, 31(4), pp.263-295.
- 이정환·조진형·장홍준 (2022), “기업의 ESG 성과가 비대칭적 변동성에 미치는 영향”, *재무관리연구*, 39(2), pp.217-245.
- 임병권·박재환 (2017), “신규분석 기업에 대한 애널리스트의 정보적 가치에 관한 연구”, *금융공학연구*, 16(1), pp.49-74.
- 임옥빈·김동현·김병진 (2022), “기업의 ESG 성과가 신용평가에 미치는 영향”, *세무와회계저널*, 23(3), pp.41-67.
- 정석우·한형성·임태균, (2011), “재무분석가의 베스트 선정 및 산업전문성과 예측특성”, *한국증권학회지*, 40(5), pp.749-774.
- 전진규 (2021), “ESG Factors as a Determinant on Credit Ratings”, *재무연구*, 34(2), pp.31-65.
- 최금화·강상구 (2021), “B2B 산업과 B2C 산업 간 기업의 사회적 책임과 추가급락 위험에 관한 연구”, *보험금융연구*, 32(4), pp.115-144.
- 최종서·노정희 (2016), “자발적으로 공시된 탄소배출정보의 유용성”, *회계학연구*, 41(6호), pp.105-157.
- Altman, N. and Krzywinski, M., (2017), “Ensemble methods: bagging and random forests”, *Nat. Methods*, 14, pp.933-934.
- Ayers, B.C. and Freeman, R.N., (2003), “Evidence That Analyst Following and Institutional Ownership Accelerate the Pricing of Future Earnings”, *Review of Accounting Studies*, 8, pp.47-67.
- Bradshaw, Mark T. (2009), “Analyst Information Processing, Financial Regulation, and Academic Research”, *The Accounting Review*, 84(4), pp.1073-83.

- Chapple, L., P. M. Clarkson and D.L. Gold (2013), “The cost of carbon: Capital market effects of the proposed emission trading scheme (ETS)”, *Abacus* 49(1), pp.1-33.
- Ellul, A. and Panayides, M. (2018), “Do Financial Analysts Restrain Insiders’ Informational Advantage?”, *Journal of Financial and Quantitative Analysis*, 53(1), pp.203-241.
- Jerome H. Friedman (2001), “Greedy Function Approximation: A Gradient Boosting Machine”, *The Annals of Statistics*, pp.1189-1232.
- Kim, H.J., Ryu, D.J. and Cho, H. (2019), “Corporate Default Predictions and Machine Learning”, *Korean Journal of Financial Engineering* 18(3), pp.131-152.
- Kim, Y., H. Li, and S. Li (2014), “Corporate social responsibility and stock price crash risk”, *Journal of Banking & Finance*, 43, pp.1-13.
- King, G. and Zeng, L. (2001), “Logistic Regression in Rare Events Data”, *Political Analysis* 9(2), pp.137-163.
- Lee, I.R. and Kim, D.C. (2015), “An Evaluation of Bankruptcy Prediction Models Using Accounting and Market Information in Korea”, *Asian Review of Financial Research* 28(4), pp.625-665.
- Lee, Jeong-Hwan and Jin-Hyung Cho (2021), “Firm-Value Effects of Carbon Emissions and Carbon Disclosures—Evidence from Korea”, *International Journal of Environmental Research and Public Health*, 18(22), pp.1-16.
- Lee, J.W., Lee, Y.S. and Lee, B.S. (2003), “The Determination of Corporate Debt in Korea”, *Asian Economic Journal*, pp.333-356.
- Leo Breiman (1996), “Bagging predictors”, *Machine Learning*, 24, pp.123-140.
- _____ (2001), “Random Forests”, *Machine Learning* 45, pp.5-32.
- Maria Vassalou and Yuhang Xing (2004), “Default Risk in Equity Returns”, *Journal of Finance*, 59(2), pp.831-868.
- Lys, Thomas and Sohn, Sungkyu (1990), “The association between revisions

- of financial analysts' earnings forecasts and security-price changes”, *Journal of Accounting and Economics*, 13(4), pp.341-363
- Matsumura, E.M., Prakash, R. and Vera-Munoz, S.C. (2014), “Firm-Value Effects of Carbon Emissions and Carbon Disclosures”, *The Accounting Review*, 89(2), pp.695-724.
- Merton, R. C. (1974), “On the Pricing of Corporate Debt: The Risk Structure of Interest Rates”, *Journal of Finance*, 29, pp.449-70.
- Oh, S.K., Choi, S.Y. and Park, K.N. (2015), “Structural Credit Risk Model Incorporating the First Hitting Condition of Random Default Barrier”, *THE KOREAN JOURNAL OF FINANCIAL MANAGEMENT*, 32(4), pp.23-51.
- Paul D. Childs, David C. Mauer and Steven Hott. (2005), “Interactions of corporate financing and investment decisions: The effects of agency conflicts”, *Journal of Financial Economics*, 76, pp.667-690.
- Paul M. Healy and Krishna G. Palepu (2001), “Information asymmetry, corporate disclosure, and the capital markets: A review of the empirical disclosure literature”, *Journal of Accounting and Economics*, 31(1-3), pp.405-440.
- Pando Son and Seung-Tae Son (2008), “Capital Structure's Mean-Reversion and Long-Term Equilibrium”, *Korea Financial Management Association*, 25(3), pp.33-78.
- Shahram Amini, Ryan Elmore, Ozde Oztekim and Jack Strauss (2021), “Can machines learn capital structure dynamics?”, *Journal of Corporate Finance*, 70, pp.1-22.
- Sreedhar T. Bharath and Tyler Shumway (2008), “Forecasting Default with the Merton Distance to Default Model”, *The Review of Financial Studies*, 21(3), pp.1339-1369,
- Strobl, C., Boulesteix, A., Kneib, T., Augustin, T. and Zeileis, A. (2008), “Conditional variable importance for random forests”, *BMC Bioinform*,

9, pp.307-317.

Thomas Lys and Sungkyu Sohn (1990), “The association between revisions of financial analysts' earnings forecasts and security-price changes”, *Journal of Accounting and Economics*, 13(4), pp.341-363.

Yoon, Bohyun, Jeong Hwan Lee, and Ryan Byun. (2018), “Does ESG Performance Enhance Firm Value? Evidence from Korea”, *Sustainability*, 10(10), pp. 1-18.

Abstract

Corporate Distress Probability Prediction Model Using Machine Learning Model and Non-Financial Information - Focusing on Carbon Emission Information, ESG Performance and Analyst Coverage

Jeong Hwan Lee, Jin Hyung Cho

We conduct a baseline study for developing alternative credit rating models. For this purpose, we firstly address whether involuntarily-delisted firms, a default-like event for listed firms, could be explained by current credit rating policies. Because credit ratings are very limited to bond issuing firms, we adopt a class of machine learning models to replicate the logic behind current credit rating policy. Next, we also examine the feasibility of using alternative non-financial information such as carbon emissions, ESG performance and analyst coverage in alternative credit rating models.

We show that machine learning models effectively learn the rating policies of credit rating agencies. Then we apply the logic of this model to involuntarily-delisted firms, which previously could not be analyzed due to the absence of credit rating information. We confirm that the traditional credit rating model based on financial statements adequately explains the trends of these firms.

Furthermore, we confirm the robustness of the governance performance in reducing credit risk of a corporation, which is measured by the widely used distance to default measure. However, the social and environmental scores, analyst coverage and carbon emission information were found to have no additional explanatory power in the credit risks of corporation.

The contributions of this study are as follows. First, we provide a machine

learning-based methodological framework that provides credit rating analysis to various type of firms, which were generally restricted to bond-issuing firms. Through this framework, we conduct credit rating analysis on involuntary-delisted firms, and confirm that the eventual default of firms is determined by financial factors, not non-financial factors. Moreover, our result implies that governance performance could be important in determining credit risk of a corporation. We also suggest that further analysis on whether the information, such as carbon emissions and environmental performance, is required as the perceptions on circumstantial risk may alter when alternative credit rating model is employed.

KIF Working Paper 2023-01

머신러닝과 비재무적 정보를 이용한 부실 확률 예측 모형 :
탄소배출정보, ESG 성과, 애널리스트 정보를 중심으로

2023년 1월 13일 인 쇄

2023년 1월 19일 발 행

발 행 인 박 종 규

발 행 처 한 국 금 융 연 구 원

서울시 중구 명동 11길 19 은행회관 5·6·7·8층

전화: 02-3705-6300 FAX: 02-3705-6309

<http://www.kif.re.kr> ; webmaster@kif.re.kr

등록 제1-1838(1995. 1. 28)

© 한국금융연구원 2023

※ 보고서의 연구 내용은 집필자 개인 의견으로 한국금융연구원의 공식
견해와는 무관함을 밝힙니다.